ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



XỬ LÝ NGÔN NGỮ TỰ NHIÊN (CS221)

Báo cáo đồ án

SENTIMENT ANALYSIS FOR AMAZON REVIEWS

GIẢNG VIÊN HƯỚNG DẪN: TS. NGUYỄN TRỌNG CHỈNH
TÊN NHÓM: WRONG TIMES

STT	Họ tên SV	MSSV
1	Đặng Quốc Thịnh	23521494

Nội dung

1 Giới thiệu bài toán **2**
1.1 Đặt vấn đề . . . 2
1.2 Mục tiêu nghiên cứu . . . 2

2 Bộ ngữ liệu **3**
2.1 Cách chọn bộ ngữ liệu . . . 3
2.2 Phân tích ngữ liệu . . . 4
2.2.1 Ý nghĩa các nhãn cảm xúc . . . 4
2.2.2 Phân tích một số mẫu ngữ liệu . . . 5
2.3 Thống kê ngữ liệu . . . 5
2.4 Phân tích ngữ liệu . . . 9

3 Phương pháp sử dụng-RoBERTa **28**
3.1 Kiến trúc Transformers và BERT, RoBERTa . . . 28
3.1.1 Kiến trúc Transformers . . . 28
3.1.2 Mô hình BERT . . . 30
3.1.3 Mô hình RoBERTa . . . 32
3.2 Các metric đánh giá mô hình . . . 35

4 Cài đặt **35**
4.1 Cài đặt phương pháp so sánh - Logistic Regression . . . 35
4.1.1 Tiền xử lý dữ liệu . . . 35
4.1.2 Huấn luyện mô hình Logistic Regression . . . 36
4.2 Cài đặt phương pháp so sánh - Random Forest . . . 38
4.2.1 Tiền xử lý dữ liệu . . . 38
4.2.2 Huấn luyện mô hình Random Forest . . . 39
4.3 Cài đặt phương pháp chính - RoBERTa . . . 39
4.3.1 Tiền xử lý dữ liệu . . . 39
4.3.2 Huấn luyện mô hình RoBERTa . . . 40

5 Đánh giá **41**
5.1 So sánh mô hình . . . 41
5.2 Một số trường hợp sai . . . 42

6 Tài liệu tham khảo **45**

1 Giới thiệu bài toán

1.1 Đặt vấn đề

Trong bối cảnh thương mại điện tử phát triển mạnh mẽ, các nền tảng như Amazon đã trở thành nơi người dùng chia sẻ ý kiến và đánh giá về sản phẩm thông qua các đánh giá sao (star ratings) và bình luận. Những đánh giá này không chỉ phản ánh chất lượng sản phẩm mà còn thể hiện cảm xúc, thái độ của người tiêu dùng đối với sản phẩm và dịch vụ. Phân tích cảm xúc (sentiment analysis) từ các đánh giá sao và nội dung bình luận có thể giúp các doanh nghiệp hiểu rõ hơn về nhu cầu, mong muốn và sự hài lòng của khách hàng, từ đó cải thiện sản phẩm, tối ưu hóa chiến lược kinh doanh và nâng cao trải nghiệm người dùng.
Tuy nhiên, việc phân tích cảm xúc từ các đánh giá sao trên Amazon gặp phải nhiều thách thức. Đánh giá sao thường chỉ cung cấp thông tin tổng quát về mức độ hài lòng (từ 1 đến 5 sao), nhưng không phải lúc nào cũng phản ánh chính xác cảm xúc cụ thể của người dùng. Ví dụ, một đánh giá 4 sao có thể mang tính tích cực nhưng vẫn chứa các ý kiến tiêu cực về một khía cạnh cụ thể của sản phẩm. Ngoài ra, khối lượng dữ liệu đánh giá khổng lồ đòi hỏi các phương pháp phân tích tự động, sử dụng các kỹ thuật học máy và xử lý ngôn ngữ tự nhiên (NLP) để trích xuất và phân loại cảm xúc một cách hiệu quả. Do đó, việc nghiên cứu và phát triển các mô hình phân tích cảm xúc từ đánh giá sao trên Amazon là một nhiệm vụ quan trọng, có ý nghĩa thực tiễn và khoa học cao.

1.2 Mục tiêu nghiên cứu

Dựa trên những thách thức và tầm quan trọng của việc phân tích cảm xúc từ đánh giá sao trên Amazon, nghiên cứu này hướng đến việc xây dựng và đánh giá các phương pháp phân tích tự động nhằm trích xuất thông tin cảm xúc một cách chính xác và hiệu quả. Để đạt được điều này, các mục tiêu nghiên cứu cụ thể được đề xuất nhằm định hướng rõ ràng cho quá trình thực hiện và đảm bảo mang lại giá trị thực tiễn cho doanh nghiệp cũng như đóng góp vào lĩnh vực xử lý ngôn ngữ tự nhiên.

- **Phân loại cảm xúc từ đánh giá sao:** Xây dựng mô hình học máy hoặc học sâu để phân loại cảm xúc (tích cực, tiêu cực, trung tính) dựa trên dữ liệu đánh giá sao và nội dung bình luận từ Amazon.
- **Khám phá mối quan hệ giữa đánh giá sao và nội dung bình luận:** Phân tích sự tương quan giữa số sao (1-5) và cảm xúc được thể hiện trong văn bản bình luận, từ đó đánh giá mức độ nhất quán giữa hai loại dữ liệu này.
- **Xác định các yếu tố ảnh hưởng đến cảm xúc:** Trích xuất các đặc điểm hoặc từ khóa chính trong bình luận ảnh hưởng đến cảm xúc của người dùng, chẳng hạn như chất lượng sản phẩm, dịch vụ khách hàng, giá cả, hoặc trải nghiệm giao hàng.
- **Đề xuất cải tiến cho doanh nghiệp:** Cung cấp các khuyến nghị dựa trên kết quả phân tích cảm xúc để giúp doanh nghiệp cải thiện sản phẩm và chiến lược tiếp thị, đồng thời nâng cao sự hài lòng của khách hàng.
- **Đánh giá hiệu quả của các mô hình phân tích:** So sánh hiệu suất của các mô hình học máy và học sâu (ví dụ: SVM, LSTM, BERT) trong việc phân tích cảm xúc từ dữ liệu Amazon, từ đó xác định phương pháp tối ưu nhất.

2 Bộ ngữ liệu

2.1 Cách chọn bộ ngữ liệu

Để thực hiện nghiên cứu phân tích cảm xúc từ đánh giá sao và nội dung bình luận trên Amazon, việc lựa chọn bộ ngữ liệu phù hợp là một bước quan trọng, ảnh hưởng trực tiếp đến chất lượng và tính chính xác của các mô hình phân tích. Các tiêu chí chọn bộ ngữ liệu được xác định dựa trên mục tiêu nghiên cứu và các yêu cầu kỹ thuật của bài toán, bao gồm như sau:

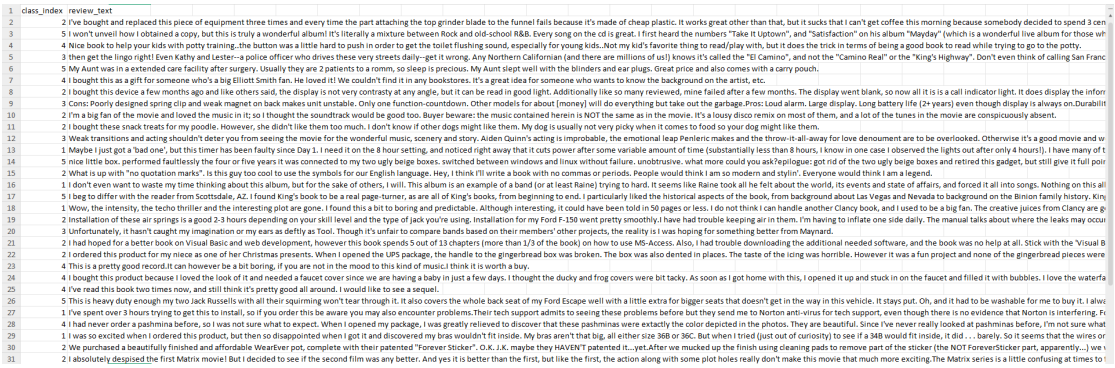
- **Độ phong phú và đa dạng của dữ liệu:** Bộ ngữ liệu cần chứa cả đánh giá sao (từ 1 đến 5) và nội dung bình luận để có thể phân tích mối quan hệ giữa hai yếu tố này. Dữ liệu nên bao gồm nhiều danh mục sản phẩm khác nhau (ví dụ: điện tử, quần áo, sách) để đảm bảo tính đại diện và khả năng tổng quát hóa của mô hình.
- **Khối lượng dữ liệu đủ lớn:** Phân tích cảm xúc đòi hỏi một lượng dữ liệu đáng kể để huấn luyện và kiểm tra các mô hình học máy hoặc học sâu. Bộ ngữ liệu cần có hàng chục nghìn đến hàng triệu đánh giá để đảm bảo tính thống kê và khả năng học hỏi của các mô hình.
- **Chất lượng và tính xác thực:** Dữ liệu cần được thu thập từ nguồn đáng tin cậy, phản ánh đúng ý kiến thực tế của người dùng. Các đánh giá phải có nội dung văn bản rõ ràng, không chứa quá nhiều lỗi chính tả hoặc nội dung không liên quan, để giảm thiểu nhiễu trong quá trình phân tích.
- **Tính sẵn có và khả năng truy cập:** Bộ ngữ liệu cần dễ dàng truy cập, được cung cấp công khai hoặc có thể thu thập thông qua các công cụ như API của Amazon hoặc các kho dữ liệu mở. Điều này giúp tiết kiệm thời gian và đảm bảo tính minh bạch trong nghiên cứu.
- **Phù hợp với mục tiêu nghiên cứu**: Bộ ngữ liệu phải hỗ trợ việc phân loại cảm xúc (tích cực, tiêu cực, trung tính) và phân tích các yếu tố ảnh hưởng đến cảm xúc (chất lượng sản phẩm, dịch vụ, giá cả). Ngoài ra, dữ liệu nên có sự phân bố cân bằng giữa các mức đánh giá sao để tránh thiên lệch trong mô hình.

Dựa trên các tiêu chí trên, bộ ngữ liệu **Amazon Reviews for Sentiment Analysis fine grained 5 classes** được chọn vì những lý do sau:

- **Đáp ứng đầy đủ các tiêu chí:** Bộ dữ liệu Amazon Reviews, với cấu trúc DatasetDict bao gồm tập huấn luyện (*train*) với 3,000,000 đánh giá và tập kiểm tra (*test*) với 650,000 đánh giá, cung cấp một khối lượng dữ liệu lớn, đảm bảo đủ để huấn luyện và đánh giá các mô hình học máy/học sâu. Mỗi mẫu dữ liệu bao gồm các đặc trưng *class_index* (đánh giá sao), *review_title* (tiêu đề đánh giá), và *review_text* (nội dung bình luận), đáp ứng yêu cầu về độ phong phú và khả năng phân tích mối quan hệ giữa đánh giá sao và nội dung văn bản.
- **Tính xác thực:** Dữ liệu được thu thập trực tiếp từ người dùng Amazon, đảm bảo phản ánh đúng ý kiến và cảm xúc thực tế của khách hàng.
- **Tính sẵn có:** Bộ dữ liệu này thường được cung cấp công khai trên các nền tảng như Kaggle hoặc kho lưu trữ của Amazon, dễ dàng tải xuống và sử dụng cho nghiên cứu học thuật.

- **Hỗ trợ mục tiêu nghiên cứu:** Với 3,000,000 mẫu trong tập huấn luyện và 650,000 mẫu trong tập kiểm tra, Amazon Reviews cho phép phân tích mối quan hệ giữa đánh giá sao và nội dung bình luận, trích xuất các yếu tố ảnh hưởng đến cảm xúc, và đánh giá hiệu quả của các mô hình như SVM, LSTM, hay BERT. Sự phân bố dữ liệu lớn và đa dạng cũng hỗ trợ việc đảm bảo tính cân bằng giữa các mức đánh giá sao.

Kết luận: Bộ ngữ liệu *Amazon Reviews for Sentiment Analysis fine grained 5 classes*, với tổng cộng 3,650,000 đánh giá (3,000,000 huấn luyện và 650,000 kiểm tra), là lựa chọn tối ưu cho nghiên cứu này nhờ vào khối lượng dữ liệu lớn, tính đa dạng, chất lượng cao, và khả năng hỗ trợ toàn diện các mục tiêu nghiên cứu. Trong đồ án, nhóm chỉ lấy 1% bộ ngữ liệu, tương ứng với khoảng 36,500 đánh giá (30,000 cho huấn luyện và 6,500 cho kiểm tra), để đảm bảo tính khả thi và hiệu quả trong phạm vi nghiên cứu. Việc sử dụng bộ dữ liệu này, ngay cả ở quy mô nhỏ hơn, vẫn giúp đảm bảo tính chính xác và hiệu quả trong quá trình phân tích cảm xúc, từ đó mang lại giá trị thực tiễn cho doanh nghiệp và đóng góp vào lĩnh vực xử lý ngôn ngữ tự nhiên.



class_index	review_text
2	I've bought and replaced this piece of equipment three times and every time the part attaching the top grinder blade to the funnel fails because it's made of cheap plastic. It works great other than that, but it sucks that I can't get coffee this morning because somebody decided to spend 3 cen
5	I won't unveil how I obtained a copy, but this is truly a wonderful album! It's literally a mixture between Rock and old-school R&B. Every song on the cd is great. I first heard the numbers "Take It Uptown", and "Satisfaction" on his album "Mayday" (which is a wonderful live album for those wh
4	Nice book to help your kids with potty training..the button was a little hard to push in order to get the toilet flushing sound, especially for young kids..Not my kid's favorite thing to read/play with, but it does the trick in terms of being a good book to read while trying to go to the potty.
3	then get the lingo right! Even Kathy and Lester--a police officer who drives these very streets daily--get it wrong. Any Northern Californian (and there are millions of us!) knows it's called the "El Camino", and not the "Camino Real" or the "King's Highway". Don't even think of calling San Franc
5	My Aunt was in a extended care facility after surgery. Usually they are 2 patients to a romm, so sleep is precious. My Aunt slept well with the blinders and ear plugs. Great price and also comes with a carry pouch.
4	I bought this as a gift for someone who's a big Elliott Smith fan. He loved it! We couldn't find it in any bookstores. It's a great idea for someone who wants to know the background on the artist, etc.
2	I bought this device a few months ago and like others said, the display is not very contrasty at any angle, but it can be read in good light. Additionally like so many reviewed, mine failed after a few months. The display went blank, so now all it is is a call indicator light. It does display the inforr
3	Cons: Poorly designed spring clip and weak magnet on back makes unit unstable. Only one function-countdown. Other models for about [money] will do everything but take out the garbage.Pros: Loud alarm. Large display. Long battery life (2+ years) even though display is always on.Durabilit
2	I'm a big fan of the movie and loved the music in it; so I thought the soundtrack would be good too. Buyer beware: the music contained herein is NOT the same as in the movie. It's a lousy disco remix on most of them, and a lot of the tunes in the movie are conspicuously absent.
2	I bought these snack treats for my poodle. However, she didn't like them too much. I don't know if other dogs might like them. My dog is usually not very picky when it comes to food so your dog might like them.
3	Weak transitions and acting shouldn't deter you from seeing the movie for the wonderful music, scenery and story. Aiden Quinn's acting is improbable, the emotional leap Penleric makes and the throw-it-all-away for love denoument are to be overlooked. Otherwise it's a good movie and w
1	Maybe I just got a 'bad one', but this timer has been faulty since Day 1. I need it on the 8 hour setting, and noticed right away that it cuts power after some variable amount of time (substantially less than 8 hours, I know in one case I observed the lights out after only 4 hours!). I have many of t
5	nice little box. performed faultlessly the four or five years it was connected to my two ugly beige boxes. switched between windows and linux without failure. unobtrusive. what more could you ask?epilogue: got rid of the two ugly beige boxes and retired this gadget, but still give it full poir
2	What is up with "no quotation marks". Is this guy too cool to use the symbols for our English language. Hey, I think I'll write a book with no commas or periods. People would think I am so modern and stylin'. Everyone would think I am a legend.
1	I don't even want to waste my time thinking about this album, but for the sake of others, I will. This album is an example of a band (or at least Raine) trying to hard. It seems like Raine took all he felt about the world, its events and state of affairs, and forced it all into songs. Nothing on this all
5	I beg to differ with the reader from Scottsdale, AZ. I found King's book to be a real page-turner, as are all of King's books, from beginning to end. I particularly liked the historical aspects of the book, from background about Las Vegas and Nevada to background on the Binion family history. Kin
1	Wow, the intensity, the techo thriller and the interesting plot are gone. I found this a bit to boring and predictable. Although interesting, it could have been told in 50 pages or less. I do not think I can handle another Clancy book, and I used to be a big fan. The creative juices from Clancy are g
2	Installation of these air springs is a good 2-3 hours depending on your skill level and the type of jack you're using. Installation for my Ford F-150 went pretty smoothly.I have had trouble keeping air in them. I'm having to inflate one side daily. The manual talks about where the leaks may occu
3	Unfortunately, it hasn't caught my imagination or my ears as deftly as Tool. Though it's unfair to compare bands based on their members' other projects, the reality is I was hoping for something better from Maynard.
2	I had hoped for a better book on Visual Basic and web development, however this book spends 5 out of 13 chapters (more than 1/3 of the book) on how to use MS-Access. Also, I had trouble downloading the additional needed software, and the book was no help at all. Stick with the 'Visual B
2	I ordered this product for my niece as one of her Christmas presents. When I opened the UPS package, the handle to the gingerbread box was broken. The box was also dented in places. The taste of the icing was horrible. However it was a fun project and none of the gingerbread pieces were
4	This is a pretty good record.It can however be a bit boring, if you are not in the mood to this kind of music.I think it is worth a buy.
4	I bought this product because I loved the look of it and needed a faucet cover since we are having a baby in just a few days. I thought the ducky and frog covers were bit tacky. As soon as I got home with this, I opened it up and stuck in on the faucet and filled it with bubbles. I love the waterfa
4	I've read this book two times now, and still think it's pretty good all around. I would like to see a sequel.
5	This is heavy duty enough my two Jack Russells with all their squirming won't tear through it. it also covers the whole back seat of my Ford Escape well with a little extra for bigger seats that doesn't get in the way in this vehicle. It stays put. Oh, and it had to be washable for me to buy it. I alwa
1	I've spent over 3 hours trying to get this to install, so if you order this be aware you may also encounter problems.Their tech support admits to seeing these problems before but they send me to Norton anti-virus for tech support, even though there is no evidence that Norton is interfering. Fe
4	I had never order a pashmina before, so I was not sure what to expect. When I opened my package, I was greatly relieved to discover that these pashminas were extactly the color depicted in the photos. They are beautiful. Since I've never really looked at pashminas before, i'm not sure what
1	I was so excited when I ordered this product, but then so disappointed when I got it and discovered my bras wouldn't fit inside. My bras aren't that big, all either size 36B or 36C. But when I tried (just out of curiosity) to see if a 34B would fit inside, it did . . . barely. So it seems that the wires or
2	We purchased a beautifully finished and affordable WearEver pot, complete with their patented "Forever Sticker". O.K. J.K. maybe they HAVEN'T patented it...yet.After we mucked up the finish using cleaning pads to remove part of the sticker (the NOT ForeverSticker part, apparently...) we v
2	I absolutely despised the first Matrix movie! But I decided to see if the second film was any better. And yes it is better than the first, but like the first, the action along with some plot holes really don't make this movie that much more exciting.The Matrix series is a little confusing at times to t

Hình 1: Ví dụ minh họa một vài mẫu ngữ liệu

2.2 Phân tích ngữ liệu

2.2.1 Ý nghĩa các nhãn cảm xúc

Bộ ngữ liệu *Amazon Reviews for Sentiment Analysis fine grained 5 classes* phân loại cảm xúc theo đánh giá từ 1 đến 5 sao, tương ứng với 5 mức độ cảm xúc từ rất tiêu cực đến rất tích cực. Dưới đây là phân tích chi tiết ý nghĩa của từng nhãn:

- Nhãn 1(Rất tiêu cực)
  - Ý nghĩa: Nhãn này biểu thị các đánh giá thể hiện sự không hài lòng mạnh mẽ, thất vọng hoặc phẫn nộ đối với sản phẩm hoặc dịch vụ. Người dùng thường sử dụng ngôn ngữ mạnh mẽ, tiêu cực, có thể bao gồm các từ như "tệ", "kinh khủng", "thất bại", hoặc mô tả những trải nghiệm tiêu cực rõ rệt như sản phẩm bị lỗi, dịch vụ kém chất lượng, hoặc không đáp ứng kỳ vọng.
  - Ví dụ minh họa:
- Nhãn 2(Tiêu cực)
  - Ý nghĩa: Nhãn này biểu thị sự không hài lòng ở mức độ vừa phải, khi sản phẩm hoặc dịch vụ có một số khuyết điểm nhưng không đến mức quá tồi tệ. Người dùng có thể

chỉ trích một số khía cạnh cụ thể như chất lượng, tính năng, hoặc dịch vụ hỗ trợ, nhưng cảm xúc không quá gay gắt.

  - Ví dụ minh họa:

- Nhãn 3(Trung tính)
  - Nhãn này biểu thị các đánh giá không rõ ràng về mặt cảm xúc, thường mang tính khách quan hoặc trung lập. Người dùng có thể mô tả sản phẩm mà không bày tỏ sự hài lòng hay không hài lòng mạnh mẽ, hoặc đánh giá có cả yếu tố tích cực và tiêu cực cân bằng nhau.
  - Ví dụ minh họa:

- Nhãn 4(Tích cực)
  - Ý nghĩa: Nhãn này thể hiện sự hài lòng ở mức độ tốt, khi sản phẩm hoặc dịch vụ đáp ứng hoặc vượt kỳ vọng một phần. Người dùng thường sử dụng các từ ngữ tích cực như "tốt", "hài lòng", "đáng tiền", và tập trung vào các khía cạnh như chất lượng, hiệu suất, hoặc trải nghiệm sử dụng.
  - Ví dụ minh họa:

- Nhãn 5(Rất tích cực)
  - Ý nghĩa: Nhãn này biểu thị sự hài lòng cao độ, khi sản phẩm hoặc dịch vụ vượt xa kỳ vọng của người dùng. Người dùng thường sử dụng ngôn ngữ nhiệt tình, tích cực, với các từ như "tuyệt vời", "xuất sắc", "hoàn hảo", và có khả năng cao sẽ mua lại hoặc giới thiệu sản phẩm.
  - Ví dụ minh họa:

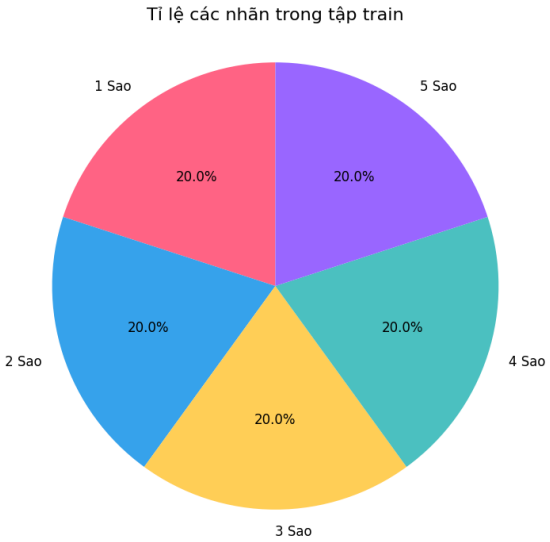
2.2.2 Phân tích một số mẫu ngữ liệu

2.3 Thống kê ngữ liệu

Trong đồ án, nhóm chỉ lấy 1% bộ ngữ liệu, tương ứng với khoảng 36,500 đánh giá (30,000 cho huấn luyện và 6,500 cho kiểm tra), nhằm đảm bảo tính khả thi và hiệu quả trong quá trình phân tích và phát triển mô hình. Dưới đây là phần thống kê ngữ liệu liên quan đến tập dữ liệu phân tích cảm xúc:

Hình ảnh biểu đồ tròn cho thấy tỷ lệ phân bố của các nhãn cảm xúc trong tập train:

- 1 Sao: 20.0%
- 2 Sao: 20.0%
- 3 Sao: 20.0%
- 4 Sao: 20.0%
- 5 Sao: 20.0%

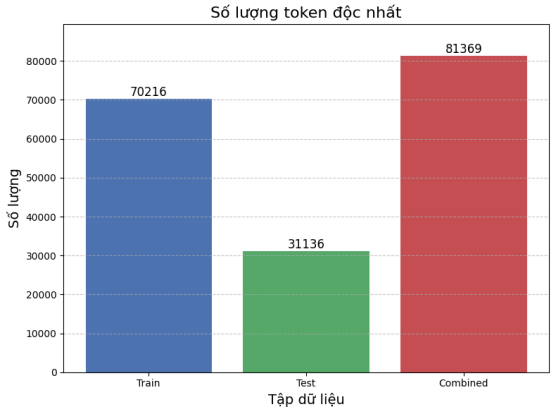


Hình 2: Tỷ lệ các nhãn trong tập train

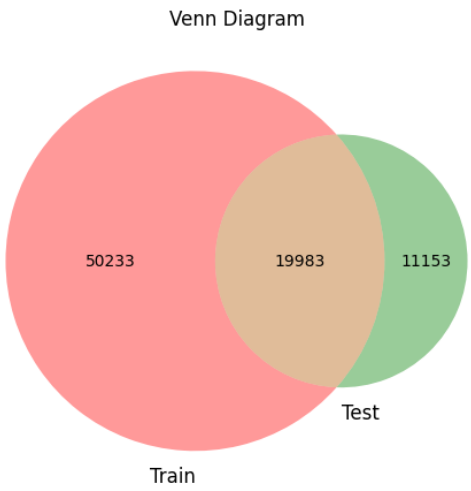
Nhận xét: Phân bố các nhãn cảm xúc trong tập test rất đồng đều, với mỗi nhãn chiếm 20%, cho thấy sự cân bằng giữa các mức độ cảm xúc từ rất tiêu cực đến rất tích cực.

Hình ảnh biểu đồ cột so sánh số lượng token theo tập dữ liệu:

- Train: 70,216 token.
- Test: 31,136 token.
- Giao nhau (có trong cả Train và Test): 19,983 token.
- Combined: 81,369 token.



Hình 3: Biểu đồ cột số lượng token trong tập dữ liệu

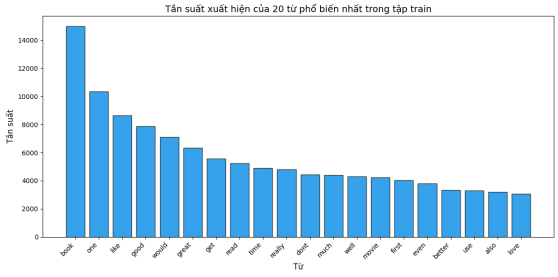


Hình 4: Biểu đồ Venn số lượng token trong tập dữ liệu

Nhận xét: Tập train có số lượng từ tọken lớn hơn tập test, trong khi tập combined (kết hợp cả train và test) đạt tổng cộng 81,369 token, phản ánh sự đa dạng của toàn bộ ngữ liệu. Có một phần lớn token riêng trong tập train (50,233), trong khi phần giao nhau (19,983) cho thấy sự tương đồng nhất định giữa hai tập dữ liệu.

Hình ảnh biểu đồ cột hiển thị tần suất xuất hiện của các từ phổ biến trong tập train:

- Từ "book": Xuất hiện với tần suất cao nhất (14,000 lần).
- Các từ khác như "one", "like", "good", "would", "great", v.v. có tần suất giảm dần, dao động từ 10,000 đến 2,000 lần.

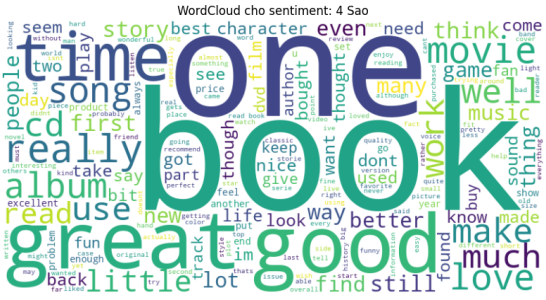


Hình 5: Tần suất xuất hiện của từ trong tập train

Nhận xét: Từ "book" chiếm ưu thế, cho thấy tập dữ liệu có thể tập trung nhiều vào đánh giá sách. Các từ như "good", "great", "like" cũng phổ biến, phản ánh xu hướng tích cực trong ngôn ngữ.

Các hình trên là WordCloud cho từng nhãn cảm xúc:

- 1 Sao: Từ "movie", "book", "don't", "problem", "bad" nổi bật, phản ánh các đánh giá tiêu cực liên quan đến vấn đề sản phẩm hoặc trải nghiệm không tốt.



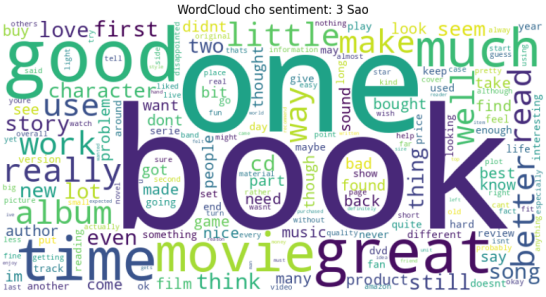
Hình 6: WordCloud cho nhãn 1 Sao

- 2 Sao: Từ "movie", "book", "good", "ok", "don't" xuất hiện, cho thấy cảm xúc trung bình với một số khía cạnh tiêu cực.



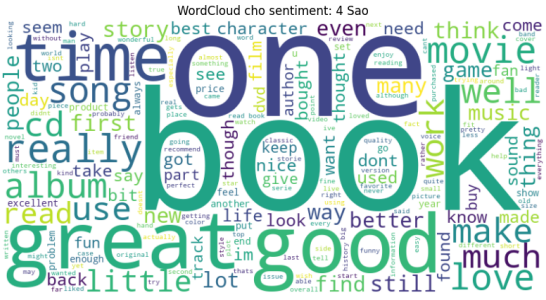
Hình 7: WordCloud cho nhãn 2 Sao

- 3 Sao: Từ "movie", "book", "good", "great", "ok" phổ biến, thể hiện đánh giá trung lập hoặc vừa phải.



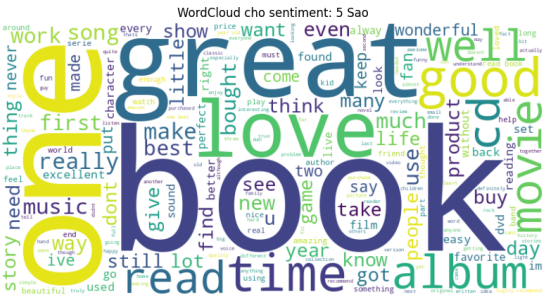
Hình 8: WordCloud cho nhãn 3 Sao

- 4 Sao: Từ "book", "movie", "good", "great", "love" nổi bật, phản ánh sự hài lòng ở mức độ tốt.



Hình 9: WordCloud cho nhãn 4 Sao

- 5 Sao: Từ "book", "movie", "great", "love", "excellent" chiếm ưu thế, thể hiện cảm xúc rất tích cực.



Hình 10: WordCloud cho nhãn 5 Sao

Nhận xét: Các từ liên quan đến "book" và "movie" xuất hiện xuyên suốt các nhãn, cho thấy nội dung đánh giá tập trung vào sách và phim. Cảm xúc thay đổi từ tiêu cực ("bad", "problem") ở 1 sao đến tích cực ("love", "excellent") ở 5 sao.

2.4 Phân tích ngữ liệu

STT	Class index	Review text	Phân tích
1	2	I've bought and replaced this piece of equipment three times and every time the part attaching the top grinder blade to the funnel fails because it's made of cheap plastic. It works great other than that, but it sucks that I can't get coffee this morning because somebody decided to spend 3 cents on a piece of plastic rather than 5.	Đánh giá 2 sao (tiêu cực) được gán do đánh giá tập trung vào khuyết điểm nghiêm trọng: bộ phận nhựa rẻ tiền liên tục hỏng ("fails", "cheap plastic"), gây bất tiện ("sucks", "can't get coffee"). Mặc dù có điểm tích cực ("works great"), vấn đề hỏng hóc lặp lại chiếm ưu thế, dẫn đến đánh giá tiêu cực.

2	5	I won't unveil how I obtained a copy, but this is truly a wonderful album! It's literally a mixture between Rock and old-school R&B. Every song on the cd is great. I first heard the numbers "Take It Uptown", and "Satisfaction" on his album "Mayday" (which is a wonderful live album for those who haven't heard it yet). If you can find a copy (as with any one of his albums) pick it up. Sorry, but those people who are trying to get $100+ for a copy are out of their minds. For crying out loud it's a cd, not the master recording! There is a difference between supply and demand, and just totally ripping people off! Pick one up if you can find it, I promise you'll enjoy it.	Nhãn 5 (rất tích cực) được gán vì đánh giá sử dụng ngôn ngữ rất tích cực ("wonderful", "great"), và nhấn mạnh mọi bài hát đều hay ("every song great"). Người viết khuyến khích mua album ("pick it up", "promise you'll enjoy") và không đề cập đến điểm tiêu cực nào liên quan đến chất lượng âm nhạc.
3	4	Nice book to help your kids with potty training..the button was a little hard to push in order to get the toilet flushing sound, especially for young kids..Not my kid's favorite thing to read/play with, but it does the trick in terms of being a good book to read while trying to go to the potty.	Nhãn 4 (tích cực) được gán vì đánh giá khen ngợi sách hữu ích cho việc tập đi vệ sinh ("nice book", "does the trick", "help with potty training"). Tuy nhiên, nhãn không đạt 5 do có một số hạn chế như nút bấm khó sử dụng ("hard to push") và không phải sách yêu thích của trẻ ("not favorite"), làm giảm mức độ hài lòng tổng thể.

4	3	then get the lingo right! Even Kathy and Lester–a police officer who drives these very streets daily–get it wrong. Any Northern Californian (and there are millions of us!) knows it's called the "El Camino", and not the "Camino Real" or the "King's Highway". Don't even think of calling San Francisco "Frisco" anywhere in the Golden State. These were not a case of the Colonel getting it wrong because he's new in town, but clearly a result of comandeering a location without any knowledge or affection for it. I found these errors, and others, very distracting.	Nhãn 3 (trung tính) được gán vì đánh giá tập trung vào các lỗi về ngôn ngữ địa phương ("wrong", "errors") gây khó chịu ("distracting"). Mặc dù chỉ trích mạnh, người viết vẫn tiếp tục đọc, cho thấy sản phẩm không quá tệ, dẫn đến nhãn trung lập.
5	5	My Aunt was in a extended care facility after surgery. Usually they are 2 patients to a romm, so sleep is precious. My Aunt slept well with the blinders and ear plugs. Great price and also comes with a carry pouch.	Nhãn 5 (rất tích cực) được gán vì đánh giá nhấn mạnh hiệu quả của sản phẩm ("slept well") trong bối cảnh giấc ngủ quan trọng ("precious"). Giá tốt ("great price") và tiện ích bổ sung ("carry pouch") củng cố sự hài lòng, không có điểm tiêu cực nào được đề cập. Dù có vài chê nhẹ ("one weak link"), người viết cực kỳ ca ngợi ("song alone worth paying. . . ", "excellent", "brilliant", "sticks with me to this day") đây là ngôn ngữ ca tụng, vượt ngưỡng của đánh giá tích cực thông thường. Mô hình có thể bị nhiễu bởi phần chê bài hát "trapped under ice" khiến mô hình không phân biệt rõ giữa ca ngợi toàn cục và chi tiết nhỏ.
6	4	I bought this as a gift for someone who's a big Elliott Smith fan. He loved it! We couldn't find it in any bookstores. It's a great idea for someone who wants to know the background on the artist, etc.	Đánh giá 4 sao (tích cực) được gán vì đánh giá nhấn mạnh sự hài lòng của người nhận ("loved it") và giá trị của sản phẩm ("great idea"). Tuy nhiên, không đạt đánh giá 5 sao do không có thêm chi tiết về chất lượng vượt trội hoặc cảm xúc mạnh hơn.

7	2	I bought this device a few months ago and like others said, the display is not very contrasty at any angle, but it can be read in good light. Additionally like so many reviewed, mine failed after a few months. The display went blank, so now all it is is a call indicator light. It does display the information in a non-standard way too, which takes some getting used to. One good things, is it read the CallerID data from every call, where my Uniden phones fail in about 10% of the calls and just say "Incomplete Data." Pass on this one, especially when better units work better and last longer for less money. The larger display is of no benefit because of it's poor readability.	Đánh giá 2 sao (tiêu cực) được gán do đánh giá tập trung vào các lỗi nghiêm trọng như màn hình khó đọc ("not very contrasty", "poor readability") và hỏng hóc ("failed", "display went blank"). Một số điểm tích cực nhỏ ("can be read in good light") không đủ để cải thiện đánh giá.
8	3	Cons: Poorly designed spring clip and weak magnet on back makes unit unstable. Only one function-countdown. Other models for about [money] will do everything but take out the garbage. Pros: Loud alarm. Large display. Long battery life (2+ years) even though display is always on. Durability: I once knocked the timer into a hot pot of cream of butternut squash soup! Fished it out with a ladle; took out the battery; unscrewed the case; rinsed it well in warm water; then turned the blow drier on it (hey, what've I got to lose?). Two hard working months later it's still as good as new.	Đánh giá 3 sao (trung tính) được gán vì đánh giá liệt kê cả ưu và khuyết điểm. Khuyết điểm bao gồm thiết kế kém ("poorly designed", "unstable"), nhưng ưu điểm như độ bền ("durability"), âm thanh lớn ("loud alarm") và pin lâu ("long battery life") cân bằng, dẫn đến đánh giá trung lập.

9	2	I'm a big fan of the movie and loved the music in it; so I thought the soundtrack would be good too. Buyer beware: the music contained herein is NOT the same as in the movie. It's a lousy disco remix on most of them, and a lot of the tunes in the movie are conspicuously absent.	Đánh giá 2 sao (tiêu cực) được gán vì đánh giá bày tỏ sự thất vọng lớn khi nhạc không đúng như kỳ vọng ("not the same", "lousy disco remix") và thiếu nhiều bài hát ("conspicuously absent"). Điểm tích cực ban đầu ("loved the music in it") không đủ để bù đắp.
10	2	I bought these snack treats for my poodle. However, she didn't like them too much. I don't know if other dogs might like them. My dog is usually not very picky when it comes to food so your dog might like them.	Đánh giá 2 sao (tiêu cực) được gán vì sản phẩm không đáp ứng kỳ vọng khi chú chó không thích ("didn't like"), đặc biệt khi chú chó này không kén ăn ("not very picky"). Đánh giá mang tính tiêu cực nhưng không quá gay gắt do người viết để ngỏ khả năng chó khác có thể thích.
11	3	Weak transitions and acting shouldn't deter you from seeing the movie for the wonderful music, scenery and story. Aiden Quinn's acting is improbable, the emotional leap Penleric makes and the throw-it-all-away for love denoument are to be overlooked. Otherwise it's a good movie and worth watching.	Đánh giá 3 sao (trung tính) được gán vì đánh giá cân bằng giữa khuyết điểm ("weak transitions", "improbable acting") và ưu điểm ("wonderful music", "good movie"). Người viết khuyến khích xem phim, cho thấy sản phẩm vẫn đáng giá dù có lỗi.

12	1	Maybe I just got a 'bad one', but this timer has been faulty since Day 1. I need it on the 8 hour setting, and noticed right away that it cuts power after some variable amount of time (substantially less than 8 hours, I know in one case I observed the lights out after only 4 hours!). I have many of these timers, mostly Intermatic, and they work great for years before any type of failure. I won't buy another Woods. :(PS: I was on vacation and didn't have time to deal with this nuisance and my product return window expired so I'm stuck with this piece of junk, which will go straight into the trash as soon as I get an Intermatic to replace it. Fortunately, it wasn't a super-expensive item.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá tập trung vào lỗi nghiêm trọng ngay từ đầu ("faulty", "bad one") và sự thất vọng lớn ("piece of junk", "won't buy another"). Không có điểm tích cực đáng kể nào được đề cập.
13	5	nice little box. performed faultlessly the four or five years it was connected to my two ugly beige boxes. switched between windows and linux without failure. unobtrusive. what more could you ask? epilogue: got rid of the two ugly beige boxes and retired this gadget, but still give it full points.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi sản phẩm hoạt động hoàn hảo ("faultlessly", "without failure") trong thời gian dài và thiết kế tiện lợi ("unobtrusive"). Không có điểm tiêu cực nào được đề cập.
14	2	What is up with "no quotation marks". Is this guy too cool to use the symbols for our English language. Hey, I think I'll write a book with no commas or periods. People would think I am so modern and stylin'. Everyone would think I am a legend.	Đánh giá 2 sao (tiêu cực) được gán vì đánh giá chế giễu phong cách viết của tác giả ("no quotation marks", "too cool"). Không có điểm tích cực nào được đề cập, thể hiện sự không hài lòng.

15	1	I don't even want to waste my time thinking about this album, but for the sake of others, I will. This album is an example of a band (or at least Raine) trying to hard. It seems like Raine took all he felt about the world, its events and state of affairs, and forced it all into songs. Nothing on this album seems like it naturally flowed from heart/mind to pen to paper. I love everything Our Lady Peace, they are my favorite band, until this record. I always told people there was not one Our Lady Peace song that I didn't enjoy. Sadly, these album leaves me with plenty. Maybe something better next time, I hope.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá sử dụng ngôn ngữ mạnh mẽ chỉ trích album ("trying to hard", "forced") và bày tỏ sự thất vọng lớn ("sadly"). Không có điểm tích cực nào được đề cập.
16	5	I beg to differ with the reader from Scottsdale, AZ. I found King's book to be a real page-turner, as are all of King's books, from beginning to end. I particularly liked the historical aspects of the book, from background about Las Vegas and Nevada to background on the Binion family history. King doesn't pad his books with filler–instead he tells a story the way a story should be told. If you like romance and/or Gone With the Wind type stuff, or descriptions of city streets that take up eight pages or so every time a descriptive passage presents itself, then you should stick with the so-called and self-proclaimed "Queen of True Crime." If you're after hard-hitting true crime that really moves, page after page, then you'll like this book and just about anything else this guy has written.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi sách hấp dẫn ("page-turner") và chi tiết lịch sử thú vị ("particularly liked", "historical aspects"). Không có điểm tiêu cực nào được đề cập.

17	1	Wow, the intensity, the techo thriller and the interesting plot are gone. I found this a bit to boring and predictable. Although interesting, it could have been told in 50 pages or less. I do not think I can handle another Clancy book, and I used to be a big fan. The creative juices from Clancy are gone like a burnt out rock star. Time for him to retire and read other's great novels.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá chỉ trích sách thiếu hấp dẫn ("boring", "predictable") và không còn các yếu tố thú vị ("gone"). Một điểm tích cực nhỏ ("interesting") không đủ để cải thiện nhãn.
18	2	Installation of these air springs is a good 2-3 hours depending on your skill level and the type of jack you're using. Installation for my Ford F-150 went pretty smoothly. I have had trouble keeping air in them. I'm having to inflate one side daily. The manual talks about where the leaks may occur, and they're right. I found it impossible to follow the directions literally and not have a significant air leak. The air leaks occur where the air fitting connects to the top of the unit. I tweaked and tweaked, and even put teflon tape on the threads (which helped a lot), but I'm still having trouble with one of them. I'll looking at an RMA soon if I can't get this resolved. I don't understand how these folks can make this heavy-duy air spring, with steel hardware to fit your vehicle perfectly, then mess it up with a poorly engineered air fitting.- FB	Đánh giá 2 sao (tiêu cực) được gán vì đánh giá tập trung vào vấn đề rò rỉ khí nghiêm trọng ("trouble keeping air", "leaks", "inflate ... daily"). Một số điểm tích cực về lắp đặt không đủ để bù đắp khuyết điểm lớn.
19	3	Unfortunately, it hasn't caught my imagination or my ears as deftly as Tool. Though it's unfair to compare bands based on their members' other projects, the reality is I was hoping for something better from Maynard.	Đánh giá 3 sao (trung tính) được gán vì đánh giá bày tỏ sự thất vọng nhẹ ("hasn't caught", "hoping for something better") nhưng không quá tiêu cực. So sánh với dự án khác làm giảm đánh giá, nhưng không có chỉ trích mạnh.

20	2	I had hoped for a better book on Visual Basic and web development, however this book spends 5 out of 13 chapters (more than 1/3 of the book) on how to use MS-Access. Also, I had trouble downloading the additional needed software, and the book was no help at all. Stick with the 'Visual Basic 6.0 Interactive Course' book (5-Star rating) and a different book on web development.	Đánh giá 2 sao (tiêu cực) được gán vì đánh giá chỉ ra nội dung không như kỳ vọng ("hoped for better") và gặp khó khăn kỹ thuật ("trouble downloading", "no help"). Không có điểm tích cực đáng kể.
21	2	I ordered this product for my niece as one of her Christmas presents. When I opened the UPS package, the handle to the gingerbread box was broken. The box was also dented in places. The taste of the icing was horrible. However it was a fun project and none of the gingerbread pieces were broken. Would not buy again.	Đánh giá 2 sao (tiêu cực) được gán vì sản phẩm bị hư hỏng ("broken", "dented") và chất lượng kém ("horrible"). Một điểm tích cực nhỏ ("fun project") không đủ để cải thiện đánh giá.
22	4	This is a pretty good record. It can however be a bit boring, if you are not in the mood to this kind of music. I think it is worth a buy.	Đánh giá 4 sao (tích cực) được gán vì đánh giá nhìn chung tích cực ("pretty good", "worth a buy"), nhưng bị giảm nhẹ do có thể gây chán ("bit boring") trong một số trường hợp.

23	4	I bought this product because I loved the look of it and needed a faucet cover since we are having a baby in just a few days. I thought the ducky and frog covers were bit tacky. As soon as I got home with this, I opened it up and stuck in on the faucet and filled it with bubbles. I love the waterfall and took a bath that night. I was having issues with the bubble dispense when I first put in super thick bubble bath. I then mixed the thick bubble bath with runnier bubble and it worked great. I do wish the bubble dispense worked a bit better as I am not 100% satisfied with it but still love it. It also does not slip off our faucet like some reviewers have complained about.	Đánh giá 4 sao (tích cực) được gán vì đánh giá nhấn mạnh thiết kế hấp dẫn ("loved the look") và sự hài lòng chung ("still love it"), nhưng có một số vấn đề nhỏ ("issues with bubble dispense", "not 100% satisfied") ngăn đạt đánh giá 5 sao.
24	4	I've read this book two times now, and still think it's pretty good all around. I would like to see a sequel.	Đánh giá 4 sao (tích cực) được gán vì đánh giá tích cực về nội dung sách ("pretty good") và mong muốn có phần tiếp theo ("sequel"). Không có chi tiết tiêu cực, nhưng thiếu sự nhiệt tình mạnh để đạt đánh giá 5 sao.
25	5	This is heavy duty enough my two Jack Russells with all their squirming won't tear through it. It also covers the whole back seat of my Ford Escape well with a little extra for bigger seats that doesn't get in the way in this vehicle. It stays put. Oh, and it had to be washable for me to buy it. I always used towels or blankets to cover the seat; this is so much better and at a reasonable price.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi độ bền ("heavy duty"), tính tiện lợi ("covers ... well", "stays put") và dễ vệ sinh ("washable"). Không có điểm tiêu cực nào được đề cập.

26	1	I've spent over 3 hours trying to get this to install, so if you order this be aware you may also encounter problems. Their tech support admits to seeing these problems before but they send me to Norton anti-virus for tech support, even though there is no evidence that Norton is interfering. For instance, turning Norton completely off does not fix the problem. Norton tech support was nice enough to thoroughly check things and they found no problem. I'm returning the software – it is useless to me.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá chỉ trích vấn đề cài đặt nghiêm trọng ("problems", "useless"). Không có điểm tích cực nào được đề cập.
27	4	I had never order a pashmina before, so I was not sure what to expect. When I opened my package, I was greatly relieved to discover that these pashminas were extactly the color depicted in the photos. They are beautiful. Since I've never really looked at pashminas before, I'm not sure what quality they should be. They are really thin and seem as though they would prick easily. I'm going to try to be careful with them. I brought five–four for my bridesmaids to wear at my wedding and one as a keepsake for myself. We all thought they were beautiful.	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi màu sắc ("beautiful") và giá tốt ("great price"), nhưng có lo ngại về độ bền ("really thin", "prick easily"), ngăn đạt đánh giá 5 sao.

28	1	I was so excited when I ordered this product, but then so disappointed when I got it and discovered my bras wouldn't fit inside. My bras aren't that big, all either size 36B or 36C. But when I tried (just out of curiosity) to see if a 34B would fit inside, it did . . . barely. So it seems that the wires on any 36 bra are too wide, but that wires of a 34 might be okay . . . but that's a close call, too. I wish they had been more upfront about needing to wear a 34B or smaller before selling them to 36Bs like myself.	Đánh giá 1 sao (rất tiêu cực) được gán vì sản phẩm không phù hợp với kỳ vọng ("disappointed", "wouldn't fit") và thiếu thông tin rõ ràng ("more upfront"). Không có điểm tích cực nào được đề cập.
29	2	We purchased a beautifully finished and affordable WearEver pot, complete with their patented "Forever Sticker". O.K. J.K. maybe they HAVEN'T patented it...yet. After we mucked up the finish using cleaning pads to remove part of the sticker (the NOT ForeverSticker part, apparently...) we were exhausted and disappointed. Our arms and fingers hurt, our beautiful new pot was marred and scarred, and we traded the pot to Wear Ever for another of their products which we could use, but still lack the product we purchased and wanted in the first place. Now, four years later, Wear Ever has maintained and even fortified it's "Forever Label" technology, if I read all the reviews correctly. Wake up Wear Ever! The FIRST thing your customer wants to do with your product, even BEFORE cooking with it is...cleaning it for it's first use. And you are relentlessly a problem thanks to your continued refusal to purchase easy to remove labeling.	Đánh giá 2 sao (tiêu cực) được gán vì vấn đề nhãn dán khó tháo ("forever sticker") làm hỏng sản phẩm ("mucked up") và gây thất vọng ("disappointed"). Một số điểm tích cực ("beautifully finished", "affordable") không đủ bù đắp.

30	2	I absolutely despised the first Matrix movie! But I decided to see if the second film was any better. And yes it is better than the first, but like the first, the action along with some plot holes really don't make this movie that much more exciting. The Matrix series is a little confusing at times to follow. And I admit, the idea of these Matrix movies is great, but were handled in the wrong way. The bonus features are nice and all. Overall, the second Matrix movie still has more talk than action and falls short of my expectations once again.	Đánh giá 2 sao (tiêu cực) được gán vì đánh giá chỉ trích phần lớn về cốt truyện yếu ("plot holes") và thiếu hấp dẫn ("don't make ... more exciting"). Mặc dù có cải thiện so với phần đầu ("better than the first"), sự không hài lòng chung vẫn chiếm ưu thế.
31	4	I bought this moisturizer as an economical alternative to L'Occitane's. As other reviewers state, it is very rich, need to dig it out from the jar. I use it after shower and after swimming to keep the skin well moiturized. However, it is somewhat greasy right after application, so I probably will use this for cold weather months.	Đánh giá 4 sao (tích cực) được gán vì đánh giá khen ngợi chất lượng dưỡng ẩm ("rich") và giá cả hợp lý ("economical"), nhưng có nhược điểm là hơi dầu ("greasy"), ngăn cản đạt đánh giá 5 sao.
32	3	I enjoyed reading this for the story line, but it didn't read as fluently as his other works. This may be because it is an earlier work, or I wondered if it is a poorly translated version.	Đánh giá 3 sao (trung tính) được gán vì đánh giá có sự cân bằng giữa điểm tích cực ("enjoyed") và điểm tiêu cực ("didn't ... fluently", "poorly translated"). Người viết vẫn thấy đáng đọc, nhưng không quá ấn tượng.

33	3	Don't get me wrong, I like this CD. But I feel it's lacking what his other solo work has. There isn't one track which stands out over the rest on this disc... they all seem to blend together. I was excited when I found he had released a new disc... but found myself slightly NOT MOVED once I reached the end of the last track. His new material speaks about being alone and not feeling loved. It reflects on a drinking problem which leads me to believe this could be the reason he is now alone and doesn't feel loved. This CD is OK - but not great. If you are a fan, you will enjoy it but be left feeling as if you want him to snap out of this mood he is in and get back to what made you a fan in the first place.	Đánh giá 3 sao (trung tính) được gán vì đánh giá bày tỏ sự thích nhẹ ("like") nhưng thất vọng về chất lượng ("lacking", "isn't ... stands out"). CD không đáp ứng kỳ vọng, nhưng vẫn được đánh giá trung bình.
34	3	I really enjoyed the first disc but the other disc not so much. However; for the price it was still a good buy. I'm not saying someone out there wouldn't enjoy the ones I didn't like. I'll give the disliked disc to a friend so it all works out in the end!	Đánh giá 3 sao (trung tính) được gán vì đánh giá chia sẻ cả thích và không thích ("enjoyed", "not so much"), nhưng tổng thể vẫn coi là đáng giá ("good buy"). Sự cân bằng này dẫn đến nhãn trung tính.
35	4	As I am a big fan of Judi Dench I appreciate her acting in all her films. In this one, I could relate to her agony and feelings of love even though she was a much older woman. I admire her for this role with no pretense of trying to look glamorous. Maggie Smith is as usual very talented and it is a double treat to have them in the same film. For lovers of violin music you will enjoy it in this film. I wished it could have gone on longer.	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi diễn xuất và cảm xúc trong phim ("appreciate", "relate"). Một số khía cạnh khác được đề cập tích cực ("enjoy", "gone on longer"), nhưng không đủ chi tiết để đạt đánh giá 5 sao.

36	3	Unlike most other readers, I found this book most compelling in its details of the ocean, storms, and the design of the boats and not in the life and death of several swordfishermen. I did not find myself personally attached to the main characters, rather I saw the protagonists as pawns in the sea of life and death. Junger's intermixing of history with current events provides the reader with perspective and context by which to comprehend the "100 year storm". Perhaps most fascinating of all is the vast lengths the Coast Guard and Navy went to save their lives and those of several of their rescuers. The selflessness of the PJs will serve as a reminder that people truly are willing to sacrifice for the aid of others. Overall, a fascinating look at a lifestyle and the circumstances surrounding it that few of us will ever know.	Đánh giá 3 sao (trung tính) được gán vì đánh giá tập trung vào các chi tiết thú vị ("fascinating") nhưng không cảm thấy gắn bó với nhân vật ("not attached"). Sự cân bằng này dẫn đến nhãn trung tính.
37	5	I put off buying a remote for my Nikon D80 for a while because I wasn't sure I "needed" it. But then whenever I would try to get a night shot, or we'd have to run back and forth to use the timer for family photos I was annoyed. So finally I gave in and bought it. I was nervous it would be difficult to use, but it's SO easy. You literally just set the camera to receive the remote and push the button. What could be easier!?! It's so small I'm a bit nervous about losing it, but thankfully it comes with a little carrying pouch that slides onto your camera strap for safe keeping. Especially for this price, it's a must have.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi tính tiện lợi ("so easy"), cần thiết ("must have") và giá trị tốt ("price"). Không có điểm tiêu cực nào được đề cập.

38	1	This movie was like smoking a $5 crack rock but with less impact on the hit. The first movie was okay I guess, the woman ended up being some prostitute. The second and third film I don't know what the hell was going on because I never made it that far. Save your $2 and buy a bag of chips and a canned soft drink for lunch.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá chỉ trích phim kém hấp dẫn ("less impact") và không đáng xem ("never made it that far"). Một điểm tích cực nhỏ ("okay") không đủ để cải thiện nhãn.
39	1	Cons One out of the three DVD did not work. Poor quality videos very grainy in some scences very disappointed Pros Can't think of any	Đánh giá 1 sao (rất tiêu cực) được gán vì sản phẩm có lỗi nghiêm trọng ("not work", "poor quality") và gây thất vọng lớn ("very disappointed"). Không có ưu điểm nào được đề cập.
40	4	The information gleaned from the personal letters written by soldiers on both sides of the battle offer a unique insight into the unimaginable suffering of the siege. Although the author's research is extensive and the amount of detail amazing, it is presented in a text book style that can be tedious at times. All in all, a great history book.	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi nội dung sâu sắc ("unique", "amazing"), nhưng phong cách trình bày kém hấp dẫn ("tedious") để đạt đánh giá 5 sao.
41	4	This is a great backpack with lots of storage space everywhere. It's also very well built and rugged (I take it to my job site, so it gets banged around a lot). I have a widescreen laptop, and it fits in there perfectly. Some with a very thick laptop may have problems getting it into the designated pocket, but mine worked fine. My only real beef is that the side net pockets aren't big enough to hold a bottle of water, even though the advertising labels showed it packed like that. Not really a big deal; I still really like this bag.	Đánh giá 4 sao (tích cực) được gán vì đánh giá khen ngợi độ bền ("rugged") và tiện lợi ("great"), nhưng có một nhược điểm nhỏ về kích thước túi lưới ("not big enough"), ngăn đạt đánh giá 5 sao.

42	5	I love these pens. I use it mostly for my checkbook register and checks. The ink is resistant to being washed and the fine tip makes filling out the register easy. I used one pen for close to 2 years so it lasts a long time. When writing on paper and it dries fast so there are no smears.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi chất lượng cao ("love", "easy"). Không có điểm tiêu cực nào được đề cập.
43	1	THIS IS NOT JOHN WAITE....JOHN WAITE IS HOT HOT HOT!! AND THIS GUY IS DEFINATELY NOT NOT NOT!!! WHAT A BUNCH OF IDIOTS!! THIS IS A VERY YOUTHFUL PAUL YOUNG NOT THAT GORGOEOUS MAN JOHN WAITE, HOW COULD ANYONE MISTAKE THOSE TWO, IT'S LIKE NIGHT AND DAY!! THIS COMPANY NEEDS TO GET ITS S*% TOGETHER!! I THINK YOU SHOULD APOLOGIZE TO JOHN..THAT WAS A SLAP IN THE FACE!! NOT TO MENTION THAT PAUL COULD ONLY WISH HE COULD SING 1/2 AS WELL AS JOHN...PAUL SOUNDS LIKE HE'S GOT A HEAD COLD OR SOMETHING..HEE HEE!! IF YOU EVER SEE THIS JOHN, JUST KNOW THAT I AM ATRUE DEVOTED FAN WHO REALLY LOVES YOUR MUSIC ABILITY!!! JULIANNE	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá sử dụng ngôn ngữ mạnh mẽ chỉ trích lỗi sai nghiêm trọng ("not John Waite", "idiots") và bày tỏ sự tức giận ("slap in the face"). Không có điểm tích cực nào được đề cập.
44	4	Get this item and you will not regret it. One shot installation and very simple. Good product and of course Amazon is excellent especially customer support. enjoy	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi sự dễ sử dụng ("simple") và chất lượng sản phẩm ("good"), nhưng thiếu chi tiết sâu sắc để đạt đánh giá 5 sao.

45	1	Upon the arrival of my new headphones i was excited. Beautiful packaging and the presentation of the look of the headphones lead me to believe i was in for a treat. Wrong, disapointment from the start. Rubber insert very unconfortable and the sound is so trashy sounding i wonder how can altec lansing put there name on this product. Air plane headphones have more quality sound than these. No exageration at all. If u read this review please do not wast ur hard earned money on the headphones. Very dissapointing!! Altec Lansing UHP301 Snugfit Earbuds w/ Silicone Ear Pads	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá chỉ trích chất lượng kém ("trashy", "uncomfortable") và bày tỏ thất vọng lớn ("very disappointing"). Không có điểm tích cực nào được đề cập ngoài bao bì.
46	1	Definitely not one of her better books. No humor. Very little plot. Dull characters. Seems like she just had to rush it out, which is unfortunate since I'm a big fan. Oh well, hopefully, the next one will be better. The last handful have been touch and go, however.	Đánh giá 1 sao (rất tiêu cực) được gán vì đánh giá chỉ trích sách thiếu chất lượng ("no humor", "little plot", "dull"). Không có điểm tích cực nào đáng kể.
47	4	My dad has been using this cologne for as long as I can remember apparently he really likes it because he religiously gets a refill. I decided to buy this for him for father's day and the shipping was so fast it was awesome!	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi sản phẩm được yêu thích ("really likes") và dịch vụ tốt ("fast"), nhưng thiếu chi tiết vượt trội để đạt đánh giá 5 sao.

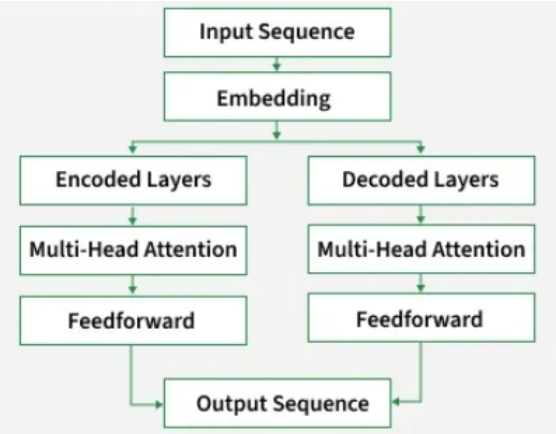
48	3	Essentially the "extras" that should have been included with the Vespertine DVD (Royal Opera House), this release is a bit thin. Don't get me wrong. I really enjoyed the behind the scenes view of the tour, but it's too little to support a separate DVD. In an age of multi-disc sets with extras longer than the main features, many of the newer Björk releases look like dinosaurs. Of course, One Little Indian has never been that concerned with value. Pick it up if you're a completist, otherwise simply get the excellent Royal Opera House concert which includes a bit of this material anyway.	Đánh giá 3 sao (trung tính) được gán vì đánh giá có sự thích nhẹ ("enjoyed") nhưng chỉ trích vì giá trị thấp ("thin", "little"). Sự cân bằng này dẫn đến nhãn trung tính.
49	5	These colored pencils are beautiful and durable. They come in a handy metal case where they can be stored to use again and again. A first-rate product.	Đánh giá 5 sao (rất tích cực) được gán vì đánh giá ca ngợi thiết kế ("beautiful"), độ bền ("durable") và tính tiện dụng ("handy"). Không có điểm tiêu cực nào được đề cập.

50	4	I had known about this album when it came out, but I wasn't interested at first. The previous Halford post Priest things didn't do anything for me - The Two project and something else. Then I caught Halford on the Iron Maiden tour 2000 and - oh man! It was awesome! The man still has his pipes - it's totally amazing. I went and checked out this CD a day or so after the show, and I should have gotten it sooner! There's some really awesome tunes on here - it's not the same musicianship as Judas Priest was (hence my 4 stars instead of 5), but it's by far the best thing he's released since Priest. If you were (or still are) a big Priest fan, you should check this out. My favorite track is "Made in Hell". Some great riffs there, and some great Halford vocals as usual.	Đánh giá 4 sao (tích cực) được gán vì đánh giá ca ngợi chất lượng cao của album ("awesome", "best"), nhưng so sánh tiêu cực với các dự án trước ("didn't do anything") và thiếu nhạc đỉnh cao hơn để đạt đánh giá 5 sao.

3 Phương pháp sử dụng-RoBERTa

3.1 Kiến trúc Transformers và BERT, RoBERTa

3.1.1 Kiến trúc Transformers

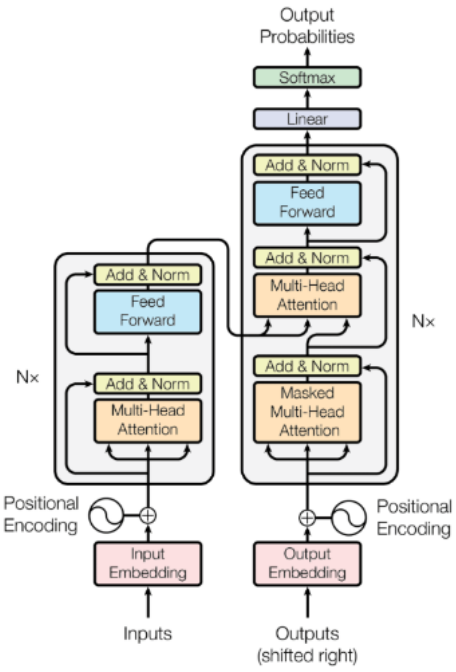


Hình 11: Transformers

Transformers là một kiến trúc mạng nơ-ron được sử dụng rộng rãi trong các nhiệm vụ học máy, đặc biệt trong xử lý ngôn ngữ tự nhiên (NLP) và thị giác máy tính. Kiến trúc này lần đầu tiên được giới thiệu trong bài báo "Attention is All You Need" của Vaswani và các cộng sự vào năm 2017. Bài viết này sẽ khám phá chi tiết về kiến trúc, cách hoạt động và các ứng dụng của Transformers, đồng thời giải thích lý do tại sao nó vượt trội hơn các mô hình truyền thống như RNNs (Recurrent Neural Networks) và LSTMs (Long Short-Term Memory).

Transformers sử dụng cơ chế tự chú ý (self-attention) để biến đổi một câu hoàn chỉnh thành một câu khác, giúp xử lý toàn bộ câu cùng một lúc thay vì tuần tự từng từ như các mô hình cũ. Điều này giúp khắc phục các hạn chế của RNNs và LSTMs, chẳng hạn như vấn đề gradient biến mất (vanishing gradient problem), dẫn đến mất khả năng ghi nhớ thông tin dài hạn. Ví dụ, trong câu "XYZ went to France in 2019 when there were no cases of COVID and there he met the president of that country", từ "that country" ám chỉ "France". Các mô hình truyền thống gặp khó khăn trong việc nắm bắt mối quan hệ ngữ cảnh này, trong khi Transformers xử lý toàn bộ câu song song nhờ cơ chế tự chú ý.

Transformers sử dụng Encoder-Decoder Architecture: Encoder chuyển đổi chuỗi đầu vào thành một vector biểu diễn, trong khi decoder tạo ra chuỗi đầu ra. Mỗi encoder và decoder bao gồm các lớp self-attention và feed-forward, với decoder bổ sung lớp encoder-decoder attention để tập trung vào các phần quan trọng của đầu vào.
Ví dụ: khi dịch câu tiếng Pháp "Je suis étudiant" sang tiếng Anh "I am a student", encoder xử lý câu nguồn và tạo ra biểu diễn ngữ nghĩa, sau đó decoder sử dụng thông tin này để tạo câu đích.

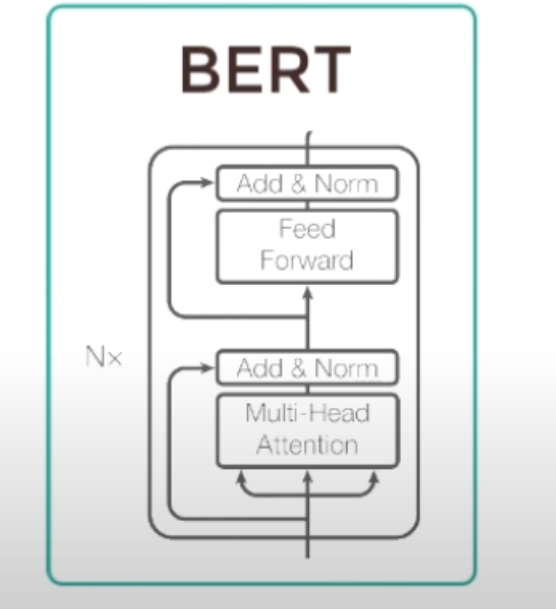


Hình 12: Kiến trúc mô hình Transformers

3.1.2 Mô hình BERT

BERT (Bidirectional Encoder Representations from Transformers) là một mô hình học sâu đột phá trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP), được phát triển bởi Google và giới thiệu trong bài báo "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding" (Devlin et al., 2018). Không giống các mô hình ngôn ngữ truyền thống, BERT tận dụng khả năng hiểu ngữ cảnh hai chiều, cho phép nó nắm bắt ý nghĩa của từ dựa trên toàn bộ câu thay vì chỉ dựa vào các từ trước hoặc sau. Bài viết này sẽ giải thích chi tiết cách BERT hoạt động, cấu trúc của nó, quy trình huấn luyện, và các ứng dụng thực tế.

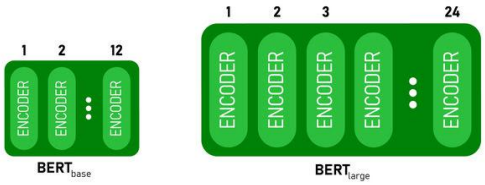
BERT là một mô hình dựa trên kiến trúc Transformer, tập trung vào việc pre-training trên dữ liệu không gắn nhãn để tạo ra các biểu diễn ngữ nghĩa phong phú. Điều làm BERT nổi bật là khả năng xử lý ngữ cảnh hai chiều, nghĩa là nó xem xét cả các từ trước và sau một từ cụ thể để hiểu ý nghĩa chính xác. Ví dụ, trong câu "Bank can refer to a financial institution or the edge of a river", BERT có thể phân biệt nghĩa của "bank" dựa trên ngữ cảnh toàn câu, điều mà các mô hình một chiều như GPT khó thực hiện.



Hình 13: Mô hình BERT

BERT sử dụng các lớp encoder của Transformer, loại bỏ phần decoder. Nó có hai biến thể chính:

- BERT-Base: Bao gồm 12 lớp encoder, 768 chiều ẩn, và 12 đầu chú ý (attention heads), với tổng cộng 110 triệu tham số.
- BERT-Large: Gồm 24 lớp encoder, 1024 chiều ẩn, và 16 đầu chú ý, với 340 triệu tham số.



Hình 14: BERT-Base và BERT-Large

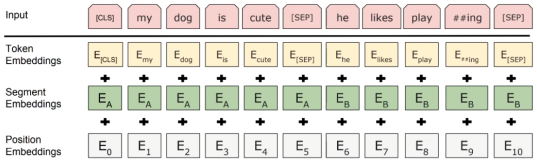
Mỗi lớp encoder bao gồm:

- Multi-Head Self-Attention: Cho phép mô hình tập trung vào các phần quan trọng của câu.
- Feed-Forward Neural Networks: Xử lý thông tin độc lập cho từng vị trí.
- Add & Norm: Kết hợp normalization và residual connections để tăng cường huấn luyện.

BERT sử dụng WordPiece để chia nhỏ văn bản thành các token. Ví dụ, từ "playing" có thể được chia thành "play" và "##ing". Quá trình này giúp xử lý từ hiếm hoặc phức tạp, với từ điển ban đầu chứa khoảng 30,000 token từ Wikipedia và BookCorpus.

Đầu vào của BERT là một chuỗi token được bổ sung các thành phần đặc biệt:

- [CLS]: Token đặc biệt ở đầu câu, dùng để phân loại (classification).
- [SEP]: Tách các câu trong cùng một đầu vào (ví dụ: câu A và câu B trong tác vụ NSP).
- Token Embeddings: Chuyển các token văn bản thành các vector số.
- Segment Embeddings: Phân biệt các câu khác nhau trong đầu vào.
- Positional Embeddings: Thêm thông tin vị trí cho từng token.

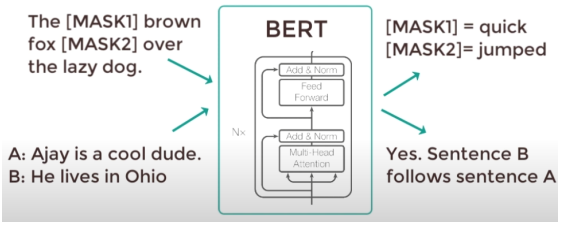


Hình 15: Input

BERT được huấn luyện theo hai giai đoạn chính: pre-training và fine-tuning:

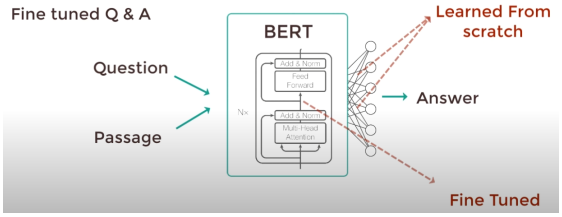
- Pre-training: được thực hiện trên dữ liệu không gắn nhãn với hai nhiệm vụ:
  - Masked Language Model (MLM): Ngẫu nhiên che 15% các token trong câu (thay bằng [MASK], giữ nguyên, hoặc thay bằng token ngẫu nhiên), sau đó dự đoán các token bị che. Trong các token được chọn: 80% được thay bằng [MASK], 10% được thay bằng token ngẫu nhiên khác, và 10% giữ nguyên. Mô hình phải dự đoán lại token gốc tại các vị trí này dựa vào biểu diễn ngữ cảnh.

– Next Sentence Prediction (NSP): Dự đoán liệu hai câu có liên quan với nhau (50% là câu tiếp theo, 50% là ngẫu nhiên). Với nhiệm vụ NSP, mô hình nhận một cặp câu (A, B) và phải dự đoán xem B có phải là câu tiếp theo thực sự của A trong văn bản gốc hay không.



Hình 16: Ví dụ pre-training

- Fine-tuning: Sau pre-training, BERT được điều chỉnh trên các tác vụ cụ thể như phân loại văn bản, câu hỏi-đáp (QA), hoặc phân tích cảm xúc. Quá trình này yêu cầu tập dữ liệu gắn nhãn và thường mất ít thời gian hơn (khoảng vài giờ trên GPU).



Hình 17: ví dụ fine-tuning

3.1.3 Mô hình RoBERTa

RoBERTa (Robustly optimized BERT approach) là một phiên bản cải tiến của mô hình BERT, được phát triển bởi nhóm nghiên cứu tại Facebook AI và giới thiệu trong bài báo "RoBERTa: A Robustly Optimized BERT Pretraining Approach" (Liu et al., 2019). Xây dựng trên nền tảng kiến trúc Transformer của BERT, RoBERTa tối ưu hóa quá trình huấn luyện để đạt hiệu suất cao hơn trên các tác vụ xử lý ngôn ngữ tự nhiên (NLP). Bài viết này sẽ trình bày chi tiết về cách RoBERTa hoạt động, các cải tiến so với BERT, cấu trúc của nó, và các ứng dụng thực tế.

RoBERTa là một mô hình ngôn ngữ pre-trained, được thiết kế để vượt qua các hạn chế của BERT bằng cách điều chỉnh chiến lược huấn luyện và sử dụng dữ liệu lớn hơn. Trong khi BERT sử dụng hai nhiệm vụ pre-training (Masked Language Model - MLM và Next Sentence Prediction - NSP), RoBERTa tập trung duy nhất vào MLM với các cải tiến quan trọng, giúp mô hình hiểu ngữ cảnh tốt hơn và đạt kết quả vượt trội trên các benchmark NLP. Ví dụ, trong câu "The movie was [MASK] but the ending was great", RoBERTa có thể dự đoán từ "good" dựa trên ngữ cảnh tối ưu hóa.

RoBERTa kế thừa kiến trúc Transformer của BERT, sử dụng các lớp encoder với hai biến thể chính:

- RoBERTa-Base: Gồm 12 lớp encoder, 768 chiều ẩn, và 12 đầu chú ý (attention heads), tương tự BERT-Base.
- RoBERTa-Large: Bao gồm 24 lớp encoder, 1024 chiều ẩn, và 16 đầu chú ý, tương đương BERT-Large.

Các thành phần chính bao gồm:

- Multi-Head Self-Attention: Tăng cường khả năng tập trung vào các phần quan trọng của câu.
- Feed-Forward Networks: Xử lý thông tin độc lập cho từng token.
- Add & Norm: Kết hợp normalization và residual connections để cải thiện quá trình huấn luyện.

RoBERTa sử dụng Byte-Pair Encoding (BPE) thay vì WordPiece của BERT, giúp chia nhỏ văn bản thành các subword hiệu quả hơn. Điều này cho phép xử lý tốt hơn các từ hiếm hoặc từ trong nhiều ngôn ngữ khác nhau.

Tương tự BERT, đầu vào bao gồm:

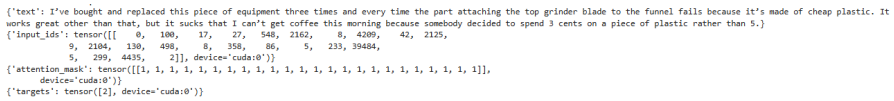
- text[CLS]: Token đặc biệt để phân loại.
- [SEP]: Tách các câu trong đầu vào.
- Token Embeddings: Chuyển các token văn bản thành các vector số.
- Segment Embeddings: Phân biệt các đoạn văn bản.
- Positional Embeddings: Thêm thông tin vị trí cho từng token.

RoBERTa được huấn luyện qua hai giai đoạn: pre-training và fine-tuning, với nhiều tối ưu hóa so với BERT:

- Pre-training: RoBERTa cải tiến quá trình pre-training bằng cách.
  - Loại bỏ NSP: Thay vì sử dụng NSP, RoBERTa chỉ tập trung vào MLM, vì nghiên cứu cho thấy NSP không mang lại lợi ích đáng kể.
  - Dynamic Masking: Thay vì che ngẫu nhiên 15% token một lần và giữ nguyên trong suốt quá trình huấn luyện (như BERT), RoBERTa áp dụng che ngẫu nhiên khác nhau trong mỗi epoch, giúp mô hình học ngữ cảnh linh hoạt hơn.
  - Dữ liệu lớn hơn: RoBERTa được huấn luyện trên 160GB văn bản (bao gồm các tập dữ liệu như BookCorpus, CC-News, OpenWebText, và Stories), so với 16GB của BERT.
  - Kích thước batch lớn: Sử dụng batch size lên đến 8,000 mẫu, so với 256 của BERT, cải thiện khả năng tổng quát hóa.
  - Huấn luyện lâu hơn: RoBERTa huấn luyện trên 500,000 bước, gấp nhiều lần so với BERT (100,000 bước).
- Fine-tuning: sau pre-training, RoBERTa được điều chỉnh trên các tác vụ cụ thể như phân loại văn bản, câu hỏi-đáp, hoặc nhận diện thực thể. Quá trình fine-tuning nhanh hơn nhờ mô hình đã học được các biểu diễn ngữ nghĩa sâu sắc.

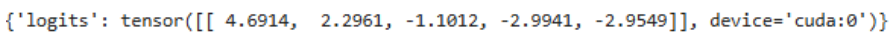
Giả sử có một câu như sau: "I've bought and replaced this piece of equipment three times and every time the part attaching the top grinder blade to the funnel fails because it's made of cheap plastic. It works great other than that, but it sucks that I can't get coffee this morning because somebody decided to spend 3 cents on a piece of plastic rather than 5." Mô hình sẽ xử lý như sau:

- Đầu tiên câu tiếng Việt trên sẽ được tiền xử lý input và trở thành 1 tensor có cấu trúc như hình bên dưới gồm có các trường: 'text' để lưu câu văn gốc chưa được thêm các token đặc biệt, 'input_ids' câu văn gốc đã được thêm các token đặc biệt sau đó được mã hóa thành số thứ tự trong bộ từ điển, 'attention_masks' dùng để chỉ ra đâu là nội dung, đâu là padding trong 'input_ids', và 'target' là nhãn của câu văn gốc.



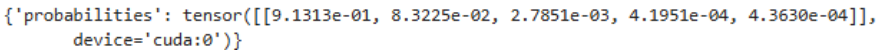
Hình 18: Ví dụ

- input_ids và attention_mask được truyền vào mô hình đã huấn luyện. Mô hình, sau khi được tinh chỉnh, tạo ra logits dựa trên embedding của [CLS] qua lớp phân loại.



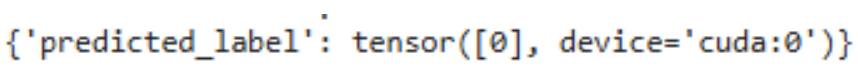
Hình 19: Ví dụ

- Áp dụng softmax để chuyển thành xác suất.



Hình 20: Ví dụ

- Mô hình sẽ dự đoán bằng cách lấy ra giá trị index của phần tử lớn nhất trong tensor trên tức là 0



Hình 21: Ví dụ

Ưu điểm của RoBERTa:

- Hiệu suất vượt trội: Đạt điểm số cao hơn BERT trên các benchmark như GLUE (94.1% với RoBERTa-Large), RACE, và SQuAD.
- Tối ưu hóa ngữ cảnh: Dynamic masking và dữ liệu lớn giúp mô hình hiểu ngữ cảnh tốt hơn.

  Khả năng mở rộng: Phù hợp với các tác vụ phức tạp nhờ quy mô huấn luyện lớn.

Hạn chế của RoBERTa:

- Yêu cầu tài nguyên khổng lồ: Cần phần cứng mạnh (GPU/TPU) và thời gian huấn luyện dài.
- Phức tạp triển khai: Khó áp dụng trên các thiết bị có tài nguyên hạn chế.
- Phụ thuộc dữ liệu: Hiệu suất phụ thuộc vào chất lượng và số lượng dữ liệu huấn luyện.

RoBERTa là một bước tiến quan trọng trong NLP, cải tiến BERT bằng cách tối ưu hóa chiến lược huấn luyện và sử dụng dữ liệu quy mô lớn. Với hiệu suất vượt trội và khả năng xử lý ngữ cảnh linh hoạt, RoBERTa đã trở thành một trong những mô hình pre-trained mạnh mẽ nhất.

3.2 Các metric đánh giá mô hình

Việc đánh giá hiệu suất của các mô hình học máy, đặc biệt trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP) như Transformer, BERT, và RoBERTa, là một bước quan trọng để đo lường khả năng tổng quát hóa và độ chính xác của mô hình trên dữ liệu mới. Các metric đánh giá được lựa chọn tùy thuộc vào loại tác vụ (phân loại, hồi quy, câu hỏi-đáp, v.v.) và mục tiêu cụ thể của bài toán.
Accuracy: Đo lường tỷ lệ dự đoán đúng của mô hình so với tổng số mẫu trong tập dữ liệu. Thích hợp cho các tác vụ phân loại cân bằng, nơi các lớp (class) có số lượng mẫu tương đương nhau.

$$\text{Accuracy} = \frac{\text{Số lượng dự đoán đúng}}{\text{Tổng số lượng mẫu}} \tag{1}$$

Precision: Đo lường tỷ lệ các dự đoán dương tính đúng so với tổng số dự đoán dương tính. Quan trọng trong các bài toán nơi giảm thiểu sai sót dương tính (false positives) là ưu tiên, như phát hiện spam.

$$\text{Precision} = \frac{\text{True Positives (TP)}}{\text{True Positives (TP)} + \text{False Positives (FP)}} \tag{2}$$

Recall: Đo lường tỷ lệ các mẫu dương tính thực tế được mô hình dự đoán đúng. Hữu ích khi cần phát hiện tất cả các trường hợp dương tính, như trong y tế (phát hiện bệnh).

$$\text{Recall} = \frac{\text{True Positives (TP)}}{\text{True Positives (TP)} + \text{False Negatives (FN)}} \tag{3}$$

F1-Score: Trung bình điều hòa của precision và recall. Thích hợp cho dữ liệu không cân bằng, ví dụ phân loại văn bản cảm xúc với các lớp thiểu số.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{4}$$

Confusion Matrix: là một công cụ trực quan hóa hiệu suất mô hình, hiển thị True Positives (TP), False Positives (FP), True Negatives (TN), và False Negatives (FN) cho từng lớp. Giúp phân tích chi tiết lỗi của mô hình, đặc biệt trong phân loại đa lớp (multi-class classification).

4 Cài đặt

4.1 Cài đặt phương pháp so sánh - Logistic Regression

4.1.1 Tiền xử lý dữ liệu

Ánh xạ nhãn: chuyển đổi nhãn từ [1, 5] thành [0, 4] để phù hợp với chỉ số lớp trong mô hình học máy.

Chuyển thành chữ thường: để loại bỏ sự khác biệt do chữ hoa/chữ thường, giúp thống nhất dữ liệu.

Loại bỏ dấu câu: xóa các ký tự như dấu chấm, phẩy, hoặc dấu chấm than, tránh nhiễu trong phân tích.

Tách từ: word_tokenize từ thư viện NLTK tách văn bản thành các token riêng lẻ.

Loại bỏ stop words: Sử dụng danh sách stop words của tiếng Anh để loại bỏ các từ không mang ý nghĩa như "the", "is", "and". Chỉ giữ lại các từ là chữ cái để loại bỏ số hoặc ký tự đặc biệt còn sót.

Vector hóa TF-IDF được cấu hình với:

- max_features=5000: Giới hạn số lượng đặc trưng tối đa là 5,000 để giảm chiều dữ liệu và tránh overfitting.
- ngram_range=(1, 2): Cân nhắc cả unigram (1 từ) và bigram (2 từ) để nắm bắt mối quan hệ giữa các từ lân cận.
- max_df=0.8: Loại bỏ từ xuất hiện quá 80% tài liệu, thường là từ không mang thông tin đặc trưng.
- min_df=5: Chỉ giữ từ xuất hiện ít nhất 5 lần, loại bỏ từ hiếm gặp.

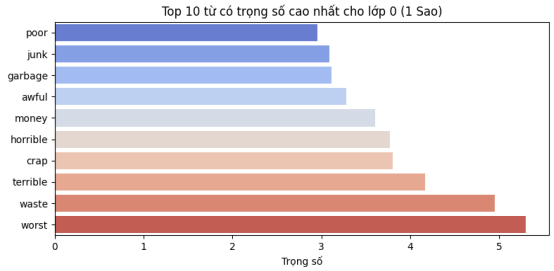
Tập huấn luyện và tập kiểm tra được chuyển thành ma trận thưa để huấn luyện.

4.1.2 Huấn luyện mô hình Logistic Regression

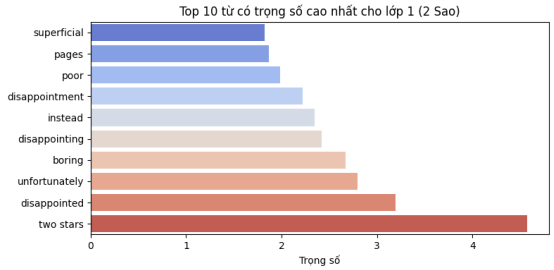
Sử dụng LogisticRegression từ scikit-learn với các tham số:

- C=1: Tham số điều chỉnh độ mạnh của regularization L2, giá trị 1 là mức trung bình, không quá mạnh hoặc quá yếu.
- penalty='l2': Áp dụng regularization L2 để ngăn overfitting bằng cách thêm hình phạt cho các trọng số lớn.
- solver='liblinear': Thuật toán tối ưu hóa dựa trên tọa độ giảm gradient, phù hợp với tập dữ liệu vừa và nhỏ, đồng thời hỗ trợ tốt cho bài toán đa lớp.
- max_iter=1000: Số lần lặp tối đa để đảm bảo mô hình hội tụ, đặc biệt với dữ liệu phức tạp.

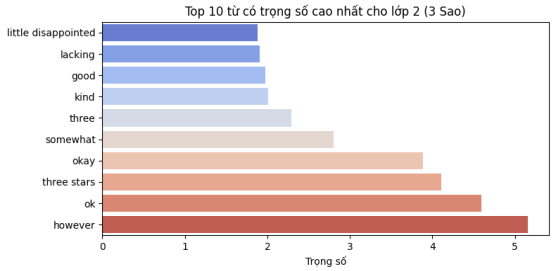
Sau khi huấn luyện xong mô hình Logistic Regression, ta tìm được các từ có trọng số cao nhất với mỗi lớp. Trọng số trong mô hình logistic regression là một tham số quan trọng được học từ dữ liệu huấn luyện. Nó đại diện cho mức độ ảnh hưởng của mỗi đặc trưng (ở đây là các từ) đối với xác suất phân loại vào một lớp cụ thể, chẳng hạn như tiêu cực, trung tính, hoặc tích cực.



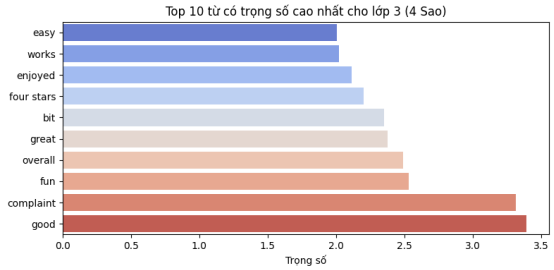
Hình 22: Tần suất xuất hiện của từ trong tập train



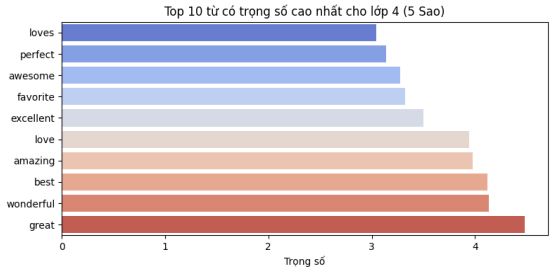
Hình 23: Tần suất xuất hiện của từ trong tập train



Hình 24: Tần suất xuất hiện của từ trong tập train



Hình 25: Tần suất xuất hiện của từ trong tập train



Hình 26: Tần suất xuất hiện của từ trong tập train

Dựa trên 5 biểu đồ bar chart được cung cấp:

- Lớp 0: Các từ như "worst", "waste", "terrible", "crap", "horrible" có trọng số cao (gần 5), cho thấy chúng thường xuất hiện trong văn bản tiêu cực. Các từ như "poor", "junk", "garbage" có trọng số thấp hơn (khoảng 2-3).
- Lớp 1: Các từ như "two stars", "disappointed", "unfortunately" có trọng số cao (gần 4-5), phản ánh ý kiến trung lập hoặc hơi tiêu cực. Các từ như "superficial", "pages", "poor" có trọng số thấp hơn (khoảng 2).
- Lớp 2: Các từ như "however", "ok", "three stars" có trọng số cao (gần 4-5), chỉ ra xu hướng tích cực nhẹ. Các từ như "little disappointed", "lacking" có trọng số thấp hơn (khoảng 1-2).
- Lớp 3: Các từ như "good", "complaint", "fun" có trọng số cao (gần 3-3.5), thể hiện ý kiến tích cực. Các từ như "easy", "works", "enjoyed" có trọng số thấp hơn (khoảng 1-2).
- Lớp 4: Các từ như "great", "wonderful", "best", "amazing" có trọng số cao (gần 4-5), phản ánh văn bản rất tích cực. Các từ như "loves", "perfect", "awesome" có trọng số thấp hơn (khoảng 2-3).

4.2 Cài đặt phương pháp so sánh - Random Forest

4.2.1 Tiền xử lý dữ liệu

Sử dụng cùng dữ liệu đã tiền xử lý và vector hóa bằng TfidfVectorizer như trong Logistic Regression để đảm bảo tính nhất quán giữa các mô hình.
Ánh xạ nhãn: chuyển đổi nhãn từ [1, 5] thành [0, 4] để phù hợp với chỉ số lớp trong mô hình học máy.

Chuyển thành chữ thường: để loại bỏ sự khác biệt do chữ hoa/chữ thường, giúp thống nhất dữ liệu.

Loại bỏ dấu câu: xóa các ký tự như dấu chấm, phẩy, hoặc dấu chấm than, tránh nhiễu trong phân tích.

Tách từ: word_tokenize từ thư viện NLTK tách văn bản thành các token riêng lẻ.

Loại bỏ stop words: Sử dụng danh sách stop words của tiếng Anh để loại bỏ các từ không mang ý nghĩa như "the", "is", "and". Chỉ giữ lại các từ là chữ cái để loại bỏ số hoặc ký tự đặc biệt còn sót.

Vector hóa TF-IDF được cấu hình với:

- max_features=5000: Giới hạn số lượng đặc trưng tối đa là 5,000 để giảm chiều dữ liệu và tránh overfitting.
- ngram_range=(1, 2): Cân nhắc cả unigram (1 từ) và bigram (2 từ) để nắm bắt mối quan hệ giữa các từ lân cận.
- max_df=0.8: Loại bỏ từ xuất hiện quá 80% tài liệu, thường là từ không mang thông tin đặc trưng.
- min_df=5: Chỉ giữ từ xuất hiện ít nhất 5 lần, loại bỏ từ hiếm gặp.

Tập huấn luyện và tập kiểm tra được chuyển thành ma trận thưa để huấn luyện.

4.2.2 Huấn luyện mô hình Random Forest

Sử dụng RandomForestClassifier từ scikit-learn với các tham số chi tiết:

- n_estimators=300: Số lượng cây quyết định trong rừng, tăng lên 300 để cải thiện độ chính xác bằng cách giảm phương sai, mặc dù có thể tăng thời gian huấn luyện.
- max_depth=30: Giới hạn độ sâu tối đa của mỗi cây để kiểm soát overfitting, cho phép cây đủ sâu để học các mẫu phức tạp nhưng không quá phức tạp.
- min_samples_split=5: Số lượng mẫu tối thiểu cần thiết để chia một nút, giúp tránh chia quá mức trên các nút nhỏ, cải thiện độ ổn định.
- min_samples_leaf=2: Số lượng mẫu tối thiểu tại mỗi lá cây, đảm bảo lá không quá nhỏ và tăng tính tổng quát.
- max_features='log2': Số lượng đặc trưng được xem xét tại mỗi lần chia, sử dụng log2 của tổng số đặc trưng để giảm chiều dữ liệu và tăng đa dạng giữa các cây.
- class_weight=None: Không áp dụng cân bằng nhãn, giả định dữ liệu đã được stratify trong quá trình chia tập; có thể điều chỉnh thành 'balanced' nếu dữ liệu mất cân bằng.
- random_state=42: Đảm bảo khả năng tái lập kết quả giữa các lần chạy.
- n_jobs=-1: Sử dụng tất cả các lõi CPU có sẵn để tăng tốc độ huấn luyện, đặc biệt hữu ích với số lượng cây lớn.

4.3 Cài đặt phương pháp chính - RoBERTa

4.3.1 Tiền xử lý dữ liệu

Chia tập dữ liệu: Tập huấn luyện được chia thành tập huấn luyện mới (80%) và tập validation (20%). Sau khi chia, tỉ lệ của 3 bộ train, val, test xấp xỉ 65:15:20.

Ánh xạ nhãn từ [1, 5] thành [0, 4] bằng remap_labels với batched=True để xử lý hàng loạt.

Sử dụng RobertaTokenizer.from_pretrained('roberta-base') để chuyển đổi văn bản thành định dạng phù hợp với mô hình RoBERTa:

- padding="max_length": Đảm bảo tất cả chuỗi đầu vào có độ dài cố định bằng cách thêm padding lên 128 token.
- truncation=True: Cắt bớt chuỗi nếu vượt quá 128 token để tránh lỗi kích thước đầu vào.
- max_length=128: Định nghĩa độ dài tối đa của chuỗi, được chọn để cân bằng giữa thông tin và hiệu suất tính toán.

RobertaTokenizer được áp dụng trên các tập train, test, và val bằng phương thức map với batched=True để tăng tốc độ xử lý.

Định dạng dữ liệu cho PyTorch bằng set_format('torch', columns=['input_ids', 'attention_mask', 'labels']), trong đó:

- input_ids: Các chỉ số token trong từ điển của RoBERTa.
- attention_mask: Mặt nạ chú ý để chỉ định token thực tế và token padding.

  item labels: Nhãn lớp của từng mẫu.

4.3.2 Huấn luyện mô hình RoBERTa

Sử dụng TrainingArguments với các tham số:

- output_dir="./results": Thư mục lưu trữ kết quả huấn luyện (model checkpoint, log, v.v.).
- eval_strategy="epoch": Thực hiện đánh giá trên tập validation sau mỗi epoch để theo dõi hiệu suất.
- warmup_steps=500: Số bước khởi động để điều chỉnh learning rate một cách từ từ, giúp ổn định huấn luyện ban đầu.
- weight_decay=0.01: Thêm regularization L2 với hệ số 0.01 để giảm thiểu overfitting.
- logging_dir='./logs': Thư mục lưu log huấn luyện.
- logging_steps=10: Ghi log sau mỗi 10 bước huấn luyện để theo dõi tiến trình.
- per_device_train_batch_size=16: Kích thước batch huấn luyện trên mỗi thiết bị (GPU/CPU), được chọn để cân bằng giữa hiệu suất và tài nguyên.
- per_device_eval_batch_size=16: Kích thước batch đánh giá, tương tự batch huấn luyện.
- num_train_epochs=3: Số lượng epoch huấn luyện, đủ để mô hình học mà không gây overfitting quá mức.
- metric_for_best_model='eval_loss': Chọn mô hình tốt nhất dựa trên loss trên tập validation, thay vì các metric khác như accuracy.

Quá trình huấn luyện: Gọi trainer.train() để thực hiện huấn luyện mô hình trên train_dataset, với đánh giá tự động trên val_dataset sau mỗi epoch. Quá trình này cập nhật trọng số mô hình dựa trên loss và lưu mô hình tốt nhất vào output_dir.

Mô hình	Accuracy	F1-Score
Logistic Regression	46%	45%
Random Forest	44%	42%
RoBERTa	58%	58%

Bảng 2: Caption

5 Đánh giá

5.1 So sánh mô hình

Dựa trên các ma trận nhầm lẫn (Confusion Matrix) và các metric đánh giá được cung cấp, ta sẽ so sánh hiệu suất của ba mô hình Logistic Regression, Random Forest, và RoBERTa trong bài toán phân loại cảm xúc với 5 lớp (1 sao đến 5 sao).
Hiệu suất tổng thể:

- RoBERTa vượt trội với độ chính xác cao nhất (58%), cho thấy khả năng hiểu ngữ cảnh văn bản tốt hơn nhờ kiến trúc Transformer và quá trình pre-training.
- Logistic Regression và Random Forest có hiệu suất thấp hơn (khoảng 44-46%), phản ánh giới hạn của các mô hình truyền thống khi xử lý dữ liệu văn bản phức tạp với đặc trưng TF-IDF.

Hiệu suất theo lớp:

- Lớp 0 và 4 (1 sao và 5 sao): Cả ba mô hình đều dự đoán tốt hơn ở các lớp cực trị, với RoBERTa đạt recall cao nhất (62% và 70%). Logistic Regression và Random Forest có recall tương đương (60-72%), nhưng precision thấp hơn.
- Lớp 1-3 (2 sao, 3 sao, 4 sao): RoBERTa có hiệu suất vượt trội với recall và F1-score cao hơn đáng kể (49-53%), trong khi Logistic Regression và Random Forest gặp khó khăn với recall dưới 37% và F1 dưới 0.38.

Điểm mạnh và điểm yếu:

- Logistic Regression: Đơn giản, nhanh chóng, nhưng hiệu suất hạn chế do không tận dụng ngữ cảnh sâu. Thích hợp làm baseline nhưng không phù hợp với dữ liệu phức tạp.
- Random Forest: Cải thiện một chút so với Logistic Regression nhờ ensemble, nhưng recall thấp ở các lớp trung gian cho thấy mô hình không học tốt các mẫu trung bình.
- RoBERTa: Vượt trội nhờ kiến trúc Transformer và pre-training, đặc biệt tốt với các lớp cực trị và có khả năng phân biệt tốt hơn giữa các mức cảm xúc nhờ dynamic masking và dữ liệu lớn.

RoBERTa là mô hình tốt nhất trong bài toán này nhờ khả năng hiểu ngữ cảnh và hiệu suất đồng đều trên các lớp. Logistic Regression và Random Forest, dù đơn giản và nhanh, không đáp ứng tốt với dữ liệu văn bản phức tạp, đặc biệt ở các lớp trung gian. Kết quả này khẳng định vai trò của mô hình Transformer trong NLP hiện đại, và việc tối ưu hóa thêm RoBERTa có thể mang lại hiệu suất cao hơn trên tập dữ liệu lớn hơn.

5.2 Một số trường hợp sai

STT	Text	Nhãn đúng	Dự đoán	Nhận xét
1	rage little different standard stephen king book first infamous bachman books also stigma publication permanently stopped columbine shootings typical horror novel like psychological thriller book revolves around high school kid traumatic childhood eventually comes via several acts escalating violence teachers administrators school also takes entire classroom hostage bizarre interactions definitely good works stephen king admirable job exploring psyche tormented mentally ill individual make think little bit particularly context world live years first published chilling preview would happen columbine schools otherwise one kings worst books.	1	2	Văn bản có nhiều ý tiêu cực ("one of King's worst books", "bizarre interactions"). Có thể vì văn bản chứa một số câu trung lập và từ tích cực như "admirable job", "permanently stopped after columbine shootings", "make you think", khiến mô hình bị "nhiễu, gặp khó khăn với đánh giá phức tạp, có cả mặt tốt và xấu, và ngữ cảnh xã hội đặc biệt (Columbine) có thể không được hiểu rõ.".
2	gave much weight amazon reviews deciding book ron ashers colloquial tamil complete beginner soon spend year semirural tamil nadu want book get speed soon possible harts book good learning read unfortunately lot basic vocabulary like used brahmins wouldnt problem hart specifically noted also gave alternate phrases doesnt although im brahmin want able communicate types people without giving offense ultimately decided go asher books unlike reviewer ashers cds found speakers spoke fast think good approximating native speech patterns however asher book cd used conjunction clear amazon page hit die.	1	2	Người viết không hài lòng ("unfortunately...", "doesn't...", "ultimately decided to go with other book", "speakers spoke fast"), từ chối sử dụng sản phẩm, nhưng văn phong trung tính ("unfortunately", "noted", "speakers spoke fast"), câu văn dài, cấu trúc phức tạp, chứa nhiều thông tin phụ khiến mô hình hiểu sai.

3	excellent photos descriptions lovely native terrestrial orchids many grow oregon washington purchased book years ago hamilton books substantial discount around.	3	4	Người viết hài lòng với sách nhưng chỉ mức độ vừa phải ("excellent photos and descriptions", "purchased years ago at discount"). Mô hình phóng đại mức độ tích cực vì xuất hiện từ "excellent", "lovely".
4	buyers remorse installing opener instruction manual accurate concise easy follow everything good quality best part quiet remote range excellent block wife likes like remote mounts outside get without getting car remote would recommend friends without hesitation.	3	4	Đây là review tích cực rõ ràng, nhưng không mang tính tán dương vượt mức ("would recommend to friends", "everything is of good quality"). Mô hình nhầm lẫn vì các từ như "excellent", "recommend without hesitation" bị hiểu là rất tích cực.
5	id honestly like give album stars since cant ill give since deserves make short sweet isnt best album done metallica holds best song fade blackthat song alone worth paying bucks guitar riff end brilliant sticks daysthe rest songs cd excellent well like ride lightning call ktulu bell tolls one weak link trapped ice thats surrounded many better songsit basically gets buy album unless course dont master puppets bucks wallet.	4	3	Dù có vài chê nhẹ ("one weak link"), người viết cực kỳ ca ngợi("song alone worth paying. . . ", "excellent", "brilliant", "sticks with me to this day") đây là ngôn ngữ ca tụng, vượt ngưỡng của đánh giá tích cực thông thường. Mô hình có thể bị nhiễu bởi phần chê bài hát "trapped under ice" khiến mô hình không phân biệt rõ giữa ca ngợi toàn cục và chi tiết nhỏ.
6	resist urge buy current thaetrical editions noticed fans happy sooner later think sooner release want would stupid gon na make much money gladly pay extended ver im big lotr fan get played way dvd version peace.	0	2	Người viết thể hiện sự tức giận, thất vọng, và có sắc thái phẫn nộ ("urge to buy. . . ", "noticed fans not happy", "release we want. . . ", "played this way for peace"). Mô hình không nắm được sự mỉa mai hoặc ẩn ý trong văn phong và các từ diễn đạt mang tính thụ động, lịch sự nhưng lại ẩn giấu cảm xúc tiêu cực, khiến mô hình khó phân loại đúng.

7	nice mount easy install radio tabs bent lock mount makes secure rattle free.	3	4	Mô tả tích cực về sản phẩm nhưng ngắn gọn, không cường điệu (“nice mount”, “secure, rattle free”). Mô hình dự đoán sai Do các tính từ như “nice”, “secure”, “easy” mô hình có thể quá nhạy cảm với từ tích cực.
8	alexander kinloch twentynineyear old son deceased fourth son earl lives alone hut windy mountainside scotland spending time painting playing bagpipes alexander receives word mother london stepfather dying stepfather ivan george westering owns brewery pillar british jockey club leaving see ivan mother alexander beaten four thugs ransack hut london learns discrepancy accounts ivans brewery large sum money missing francis created another likeable protagonist alexander kinloch memorable supporting cast helpers villains horses peripheral issue book authors thirtyfifth novel interesting touches medieval history add spice fastpaced story.	3	2	Văn bản mô tả nội dung truyện hấp dẫn, nhân vật hay (“interesting touches”, “fast-paced story”, “memorable supporting cast”) cho thấy đây là một đánh giá khen ngợi nhẹ nhàng. Mô hình dự đoán sai vì phần lớn đoạn văn là tóm tắt nội dung, không trực tiếp khen chê — gây nhầm tưởng là trung lập.
9	even though says color says white box said white definitely pink big supporter breast cancer foundation also big foodie chef great tool home pulse button held thats thing dont like dont mind home use cute doesnt take lot space.	4	3	Người viết thể hiện sự yêu thích mạnh mẽ (“cute”, “great tool”, “big supporter”, “dont mind”) với sự gắn bó cá nhân ((breast cancer support, cooking). Mô hình dự đoán sai vì có sự đề cập “definitely pink” có thể gây hiểu lầm là phàn nàn, làm giảm mức đánh giá tích cực trong mắt mô hình.

10	im sure story womans survival nightmarish mauling grizzly bear indictment canadian health care system thank goodness book fairly short read many pages yet another infection bout depression hospitalization doctor wouldnt believe pain think would needed medication read way end moment enlightement epiphany title seemed promise never arrived hoping kind information people actually cope devastating horror lives nothing page page seemingly pointless suffering without redemption relief.	1	2	Toàn văn là lời phàn nàn, thất vọng ("fairly short read", "infection", "hospitalization", "no enlightenment or epiphany ever arrived") và người viết cảm thấy bị lừa dối bởi tiêu đề và không tìm được giá trị từ cuốn sách. Văn phong tương đối bình tĩnh, kể chuyện, không dùng ngôn từ cảm xúc mạnh khiến mô hình dễ đánh giá nhầm là trung lập.

6 Tài liệu tham khảo

Tài liệu

[1] "Support Vector Machines," [Online]. Available: https://scikit-learn.org/stable/modules/svm.html.

[2] Dang Van Thin, Duong Ngoc Hao, Ngan Luu-Thuy Nguyen, "Sentiment Analysis in Code-Mixed Vietnamese-English Sentence-level," Association for Computational Linguistics, 2022.

[3] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, Veselin Stoyanov, "RoBERTa: A Robustly Optimized BERT Pretraining Approach," 2019.

[4] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," 2019.

[5] Dat Quoc Nguyen, Anh Tuan Nguyen, "PhoBERT: Pre-trained language models for Vietnamese," 2020.

[6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin, "Attention Is All You Need," 2017.

[7] "The A-Z guide to Support Vector Machine," [Online]. Available: https://www.analyticsvidhya.com/blog/2021/06/support-vector-machine-betterunderstanding/.

[8] "Grid Searching From Scratch using Python," 2024. [Online]. Available: https://www.geeksforgeeks.org/grid-searching-from-scratch-using-python/.

[9] "Optimizer - Hiểu sâu về các thuật toán tối ưu (GD, SGD, Adam,..)," [Online]. Available: https://viblo.asia/p/optimizer-hieu-sau-ve-cac-thuat-toan-toi-uu-gdsgdadamQbq5QQ9E5D8.

[10] N. C. Thắng, "Thử nhận diện cảm xúc văn bản Tiếng Việt với PhoBert," [Online]. Available: https://miai.vn/2020/12/29/bert-series-chuong-3-thu-nhan-dien-cam-xuc-vanban-tieng-viet-voi-phobert-cach-1/.

[11] "Cách tách từ cho Tiếng Việt," [Online]. Available: https://streetcodevn.com/blog/vntok.

[12] L. T. Hương, "Tách từ tiếng Việt," [Online]. Available: https://users.soict.hust.edu.vn/huonglt/UNLP/3_wordsegmentation.pdf.

[13] "Simple Sentiment Analysis — Python," [Online]. Available: https://medium.com/analytics-vidhya/simple-sentiment-analysis-python-bf9de2d75d0.